ỦY BAN NHÂN DÂN

THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

XÂY DỰNG HỆ THỐNG TỰ ĐỘNG NHẬN DIỆN TẾ BÀO UNG THƯ XƯƠNG THÔNG QUA ẢNH CHỤP X-QUANG

Mã số đề tài: SVC2025-184

Thuộc nhóm ngành khoa học: Kỹ thuật

Chủ nhiệm đề tài: Trần Đồng Gia Hân

Thành viên tham gia:

1. Trần Đồng Gia Hân
2. Lê Thị Thanh Ngân
3. Trần Minh Chiến
4. Vũ Đức Tình

Giảng viên hướng dẫn: TS. Đỗ Như Tài

TP. HỒ CHÍ MINH, 01/2026

ỦY BAN NHÂN DÂN

THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

XÂY DỰNG HỆ THỐNG TỰ ĐỘNG NHẬN DIỆN TẾ BÀO UNG THƯ XƯƠNG THÔNG QUA ẢNH CHỤP X-QUANG

Mã số đề tài: SVC2025-184

Xác nhận của Khoa	**Giáo viên hướng dẫn**	**Chủ nhiệm đề tài**
(ký, họ tên)	*(ký, họ tên)*	*(ký, họ tên)*

TP. HỒ CHÍ MINH, 01/2026

MỤC LỤC

Trang

DANH MỤC BẢNG BIỂU ..... **iv**
DANH MỤC HÌNH ẢNH ..... **v**
DANH MỤC CÁC CHỮ VIẾT TẮT ..... **vi**
TÓM TẮT **1**
PHẦN MỞ ĐẦU **2**
1. Lý do chọn đề tài 2
2. Lịch sử nghiên cứu vấn đề 3
3. Mục đích và nhiệm vụ nghiên cứu 4
4. Đối tượng và phạm vi nghiên cứu 5
5. Phương pháp nghiên cứu 6
6. Những đóng góp mới của đề tài 7
7. Cấu trúc của đề tài: 7
PHẦN NỘI DUNG **8**
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT **8**
1.1. Tổng quan về ung thư xương 8
1.1.1. Định nghĩa 8
1.1.2. Nguyên nhân và tỷ lệ mắc bệnh ung thư xương 8
1.1.2.1. Nguyên nhân gây ra ung thư xương 8
1.1.2.2. Tỷ lệ mắc bệnh ung thư xương 9
1.2. Học sâu trong chẩn đoán ung thư xương 9
1.2.1. Tổng quan về học sâu 10
1.2.2. Nguyên lý cơ bản và mạng nơ-ron trong học sâu 10
1.2.3. Kiến trúc mạng nơ-ron tích chập – CNN 11
1.2.4. Học sâu trong y học và chẩn đoán hình ảnh ý tế 12
1.2.4.1. Ứng dụng của học sâu trong y học 12
1.2.4.2. Vai trò của học sâu trong chẩn đoán hình ảnh ý tế 12
1.3. Kỹ thuật học sâu trong chẩn đoán ảnh y tế 13
1.4. U-Net trong phân đoạn ảnh y tế 14
1.4.1. Kiến trúc và nguyên lý hoạt động của U-Net 14
1.4.2. Lợi thế của U-Net trong phân đoạn ảnh 15

1.5. Các công nghệ và framework.....15
1.5.1. Giới thiệu về PyTorch.....15
1.5.2. Giới thiệu về MONAI.....16
1.5.3. PyTorch Lightning.....16
1.6. Các nghiên cứu liên quan.....17
1.6.1. Ứng dụng cơ chế chú ý và dung hợp đa tỷ lệ vào mô hình YOLO.....17
1.6.2. Tự động hóa phát hiện và phân loại u xương vùng đầu gối trên ảnh X-quang.....17
1.6.3. Kết luận.....18
CHƯƠNG 2: DỮ LIỆU VÀ CÁC PHƯƠNG PHÁP ĐỀ XUẤT.....20
2.1. Phân tích và chuẩn bị dữ liệu.....20
2.1.1. Nguồn dữ liệu.....20
2.1.2. Thống kê đặc điểm dữ liệu.....21
2.1.2.1. Phân bố theo lớp bệnh lý (Class Distribution).....21
2.1.2.2. Đặc điểm nhân khẩu học (Demographics).....22
2.1.2.3. Phân bố theo vị trí giải phẫu (Anatomical Distribution).....22
2.1.2.3. Phân bố chi tiết theo loại bệnh lý (Pathological Types).....24
2.2. Quy trình huấn luyện mô hình học sâu.....25
2.3. Tiền xử lý dữ liệu.....26
2.3.1. Thu thập và tổ chức dữ liệu.....27
2.3.2. Đọc và chuẩn hóa ảnh đầu vào.....27
2.3.3. Tạo mặt nạ phân đoạn từ dữ liệu chú thích.....27
2.3.4. Chuyển đổi sang bài toán phân đoạn nhị phân.....28
2.3.5. Gán nhãn mức ảnh.....28
2.3.6. Chuẩn hóa kích thước ảnh và mặt nạ.....28
2.3.7. Chuẩn hóa cường độ ảnh.....29
2.3.8. Tăng cường dữ liệu cho tập huấn luyện.....29
2.3.9. Chuyển đổi dữ liệu sang dạng tensor.....29
2.3.10. Chia tập dữ liệu và cân bằng mẫu huấn luyện.....29
2.3.11. Dữ liệu đầu vào cho mô hình.....30
2.4. Phương pháp đề xuất.....30
2.4.1. Tổng quan phương pháp và bài toán giải quyết.....30

2.4.2. Câu paper-line và đóng góp chính 30
2.4.3. Kiến trúc mạng đề xuất 31
2.4.4. Pipeline huấn luyện và suy luận 33
2.4.5. Biểu diễn toán học của hàm loss 34
2.4.6. Mục tiêu huấn luyện và tối ưu 35
2.4.7. Phân tích cải thiện so với U-Net chuẩn 35
CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM 37
3.1. Môi trường thực nghiệm và cấu hình huấn luyện 37
3.1.1. Môi trường thực nghiệm 37
3.1.2. Cấu hình huấn luyện và chiến lược tối ưu 37
3.2. Kết quả định lượng 38
3.2.1. Hiệu năng phân đoạn 38
3.2.2. Hiệu năng phân loại toàn cục 39
3.2.3. Phân tích ma trận nhầm lẫn 39
3.2.4. So sánh hiệu năng với các nghiên cứu quốc tế 41
3.3. Ứng dụng thực tiễn 42
3.2.1. Xây dựng hệ thống tự động nhận diện tế bào ung thư xương thông qua ảnh chụp X-quang 42
3.2.2. Ứng dụng trong thực tiễn lâm sàng 43
PHẦN KẾT LUẬN (KHUYẾN NGHỊ) 45
TÀI LIỆU THAM KHẢO 48
THUYẾT MINH 51

DANH MỤC BẢNG BIỂU

Bảng 2. 1. Đặc điểm cơ bản của tập dữ liệu BTXRD 21
Bảng 2. 2. Bảng thống kê số lượng ảnh theo vị trí tổn thương 23
Bảng 3. 1. So sánh hiệu năng phân đoạn (mIoU) trên tập validation.....38
Bảng 3. 2. So sánh hiệu năng phân loại toàn cục trên tập validation. 39
Bảng 3. 3. So sánh hiệu năng của mô hình đề xuất với các nghiên cứu quốc tế.....41

DANH MỤC HÌNH ẢNH

Hình 2. 1. Quy trình thiết kế tập dữ liệu BTXRD 20
Hình 2. 2. Biểu đồ cột thống kê dữ liệu theo phân loại bệnh lý 22
Hình 2. 3. Biểu đồ thống kê tỉ lệ ung thư tại các vị trí xương 24
Hình 2. 4. Biểu đồ thống kê tỉ lệ ung thư theo loại bệnh lý 25
Hình 2. 5. Sơ đồ kiến trúc mạng UNet đa nhiệm (Multi-task) tích hợp nhánh phân loại và hồi quy khoảng cách. 32
Hình 2. 6. So sánh định tính trên các ca bệnh điển hình. 36
Hình 3. 1. Ma trận nhầm lẫn trên tập validation mô hình UNet-seg-classification 40
Hình 3. 2. Ma trận nhầm lẫn trên tập validation mô hình UNet-seg-distance. 40

DANH MỤC CÁC CHỮ VIẾT TẮT

STT	Ký hiệu chữ viết tắt	Chữ viết đầy đủ (Tiếng Anh)
1	AI	Artificial Intelligence
2	ANN / ANNs	Artificial Neural Network(s)
3	API	Application Programming Interface
4	BN	Batch Normalization
5	BTXRD	Bone Tumor X-ray Radiograph Dataset
6	CAD	Computer-Aided Diagnosis
7	CE	Cross-Entropy
8	CNN	Convolutional Neural Network
9	CPU	Central Processing Unit
10	CSV	Comma-Separated Values
11	CT	Computed Tomography
12	DICOM	Digital Imaging and Communications in Medicine
13	ECG	Electrocardiogram
14	EEG	Electroencephalogram
15	EHR	Electronic Health Record
16	GAN	Generative Adversarial Network
17	GPU	Graphics Processing Unit
18	GT	Ground Truth
19	ILSVRC	ImageNet Large Scale Visual Recognition Challenge
20	IoU	Intersection over Union
21	JSON	JavaScript Object Notation
22	mAP	mean Average Precision
23	mIoU	mean Intersection over Union
24	MONAI	Medical Open Network for AI
25	MRI	Magnetic Resonance Imaging
26	NIfTI	Neuroimaging Informatics Technology Initiative
27	PACS	Picture Archiving and Communication System
28	RAM	Random Access Memory

29	ReLU	Rectified Linear Unit
30	RNN	Recurrent Neural Network
31	SVM	Support Vector Machine
32	VGG(Net)	Visual Geometry Group (Network)
33	VRAM	Video Random Access Memory
34	XAI	Explainable AI
35	YOLO	You Only Look Once

TÓM TẮT

Ung thư xương nguyên phát và thứ phát đại diện cho một thách thức y tế nghiêm trọng trên toàn cầu, đặc biệt là ở các nhóm đối tượng dễ bị tổn thương như thanh thiếu niên. Mặc dù tỷ lệ mắc bệnh thấp hơn so với các loại ung thư biểu mô khác, nhưng mức độ ác tính cao, tốc độ di căn nhanh và sự phức tạp trong biểu hiện hình ảnh khiến việc chẩn đoán sớm trở thành yếu tố tiên quyết để cải thiện tiên lượng sống còn [1]. Trong bối cảnh y tế hiện đại, sự bùng nổ của trí tuệ nhân tạo (AI) và học sâu (Deep Learning) đã mở ra những hướng đi mới cho các hệ thống hỗ trợ chẩn đoán tự động (Computer-Aided Diagnosis - CAD), giúp giảm tải áp lực cho bác sĩ và chuẩn hóa quy trình đọc phim.

Nghiên cứu này tập trung vào việc xây dựng và tối ưu hóa một hệ thống nhận diện và phân đoạn vùng tổn thương ung thư xương trên ảnh X-quang thường quy. Chúng tôi sử dụng bộ dữ liệu chuẩn hóa quốc tế Bone Tumor X-ray Radiograph Dataset (BTXRD) bao gồm 3.746 ảnh đa trung tâm, đại diện cho phổ bệnh lý rộng từ lành tính đến ác tính [1]. Phương pháp đề xuất dựa trên kiến trúc mạng nơ-ron tích chập SegNet – một mô hình encoder-decoder nổi bật với cơ chế pooling indices giúp bảo toàn thông tin biên dạng tần số cao một cách hiệu quả. Để giải quyết vấn đề mất cân bằng dữ liệu nghiêm trọng giữa vùng tổn thương nhỏ và nền ảnh lớn, nghiên cứu đề xuất hàm mất mát lai ghép (Hybrid Loss Function) kết hợp giữa Dice Loss và Focal Loss, cho phép mô hình tối ưu hóa đồng thời độ chồng lấn hình học và khả năng phân loại các mẫu khó.

Kết quả thực nghiệm được đánh giá toàn diện qua các chỉ số Dice Coefficient, IoU, Precision và Recall, so sánh đối chứng với các mô hình tiên tiến như U-Net và các biến thể ResNet. Nghiên cứu không chỉ đóng góp một giải pháp công nghệ có tính ứng dụng cao, phù hợp với điều kiện cơ sở hạ tầng hạn chế tại các bệnh viện tuyến dưới ở Việt Nam, mà còn cung cấp những phân tích sâu sắc về hình thái học u xương qua lăng kính của thị giác máy tính.

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Ung thư xương là một nhóm bệnh lý đa dạng bao gồm các khối u xuất phát từ mô xương (nguyên phát) hoặc di căn từ các cơ quan khác đến xương (thứ phát). Đặc điểm sinh học của các khối u này thường bao gồm sự phá hủy cấu trúc xương nhanh chóng, xâm lấn mô mềm lân cận và di căn xa, thường là đến phổi. Do đó, việc phát hiện bệnh ở giai đoạn sớm, khi khối u còn khu trú, có ý nghĩa quyết định đối với khả năng bảo tồn chi và tỷ lệ sống sót của bệnh nhân.

Tuy nhiên việc nhận diện vùng tổn thương vẫn phụ thuộc nhiều vào kinh nghiệm bác sĩ để đánh giá các đặc điểm quan trọng như vị trí khối u, đường bờ (margin), vùng chuyển tiếp (transition zone), phản ứng màng xương (periosteal reaction) và dạng chất nền (matrix) [2]. Do đó, việc diễn giải các dấu hiệu này đòi hỏi trình độ chuyên môn cao và kinh nghiệm dày dặn. Sự chồng lấn của các cấu trúc giải phẫu 3D trên mặt phẳng 2D, cùng với sự đa dạng về hình thái tổn thương (từ tiêu xương, tạo xương đến hỗn hợp), thường dẫn đến khó khăn trong việc xác định ranh giới rõ ràng giữa mô bệnh và mô lành [3].

Khác với các phương pháp xử lý ảnh truyền thống dựa trên các bộ lọc thủ công, sự trỗi dậy của trí tuệ nhân tạo (AI), đặc biệt là học sâu (Deep Learning) với các mạng nơ-ron tích chập (CNN), đã tạo ra một cuộc cách mạng trong phân tích hình ảnh y tế. CNN có khả năng tự động học các đặc trưng phân cấp từ dữ liệu, từ đó cho phép nhận diện các mẫu hình ảnh phức tạp mà mắt thường khó phân biệt [4].

Trên thế giới, nhiều công trình tiên phong đã chứng minh hiệu quả của học sâu trong phân tích ảnh X-quang xương như He et al. [5] sử dụng ResNet để phân loại u xương, Xu et al. [2] phát triển mô hình đa trung tâm cho phát hiện khối u quanh khớp gối, và Do et al. [6] đề xuất mô hình Multi-Level Seg-Unet đạt Mean IoU 84,84% cho phân đoạn u xương đầu gối. Tuy nhiên, tại Việt Nam, chưa có công trình công bốchính thức ứng dụng học sâu cho bài toán phân đoạn khối u xương. Một số nghiên cứu y học trong nước như của bác sĩ Tuấn [7] và Hồ Kim Thương – Trần Phan Chung Thủy [8] chủ yếu tập trung vào mô tả lâm sàng và kỹ thuật chẩn đoán bằng CT-scan.

Từ đó, đề tài này hướng đến việc xây dựng mô hình học sâu có khả năng phân đoạn tự động vùng nghi ngờ ung thư xương trên ảnh X-quang, kế thừa các thành tựu quốc tế và điều chỉnh phù hợp với điều kiện triển khai tại Việt Nam. Trong bài toán u xương, mục tiêu không chỉ dừng lại ở việc phân loại (classification - bệnh hay không bệnh) hay phát hiện (detection - vị trí khối u), mà còn tiến tới phân đoạn (segmentation) - định vị chính xác từng điểm ảnh thuộc khối u. Phân đoạn chính xác cung cấp thông tin định lượng về thể tích, hình dạng và ranh giới xâm lấn.

2. Lịch sử nghiên cứu vấn đề

a. Lịch sử nghiên cứu và phát triển công nghệ chẩn đoán ung thư xương

Trong giai đoạn đầu của y học hiện đại, việc chẩn đoán ung thư xương gặp nhiều hạn chế do thiếu các công cụ hình ảnh và xét nghiệm hỗ trợ. Các bác sĩ chủ yếu dựa vào thăm khám lâm sàng và giải phẫu bệnh khi khối u đã tiến triển. Bước ngoặt lớn xảy ra năm 1895 khi Wilhelm Röntgen phát hiện ra tia X, mở ra kỷ nguyên chẩn đoán hình ảnh, cho phép quan sát cấu trúc xương mà không cần can thiệp phẫu thuật [9].

Trước năm 1970, nền tảng bệnh học được xây dựng bởi Rudolf Virchow với thuyết tế bào và mô tả mô học của Osteosarcoma, James Ewing (1921) tiếp tục phân loại u nội mô lan tỏa của xương (Ewing Sarcoma), tạo cơ sở cho tư duy điều trị phân hóa giữa phẫu thuật và xạ trị [10]. Dahlin (1957) đã tổng hợp dữ liệu 2.276 ca u xương, cung cấp cái nhìn toàn diện về dịch tễ và đặc điểm lâm sàng [11]. Tuy nhiên, do hạn chế của X-quang quy ước, các phẫu thuật viên buộc phải cắt cụt chi để đảm bảo an toàn diện cắt, khiến tỷ lệ sống 5 năm chỉ đạt 10–20% [12].

Từ 1970 đến 2000, sự ra đời của CT và MRI đã thay đổi căn bản chiến lược điều trị. MRI trở thành tiêu chuẩn vàng trong đánh giá xâm lấn mô mềm và tủy xương [13], tạo tiền đề cho phẫu thuật bảo tồn chi. Hệ thống phân giai đoạn phẫu thuật của Enneking (1980) dựa trên độ mô học, vị trí và di căn trở thành nền tảng cho phân loại u xương [14]. Song song, hóa trị tân bổ trợ được Rosen chứng minh giúp nâng tỷ lệ sống 5 năm lên 70–80% [15].

Giai đoạn 2000–2015 chứng kiến sự xuất hiện của Radiomics, khi Lambin và cộng sự định nghĩa việc trích xuất đặc trưng định lượng từ ảnh y học để phục vụ Machine Learning [16]. Các mô hình SVM và Random Forest đạt độ chính xác khoảng 75–80% trong phân biệt u lành và ác tính, dù còn phụ thuộc vào khoanh vùng thủ công.

Từ 2016 đến nay, Deep Learning đã tạo ra bước nhảy vọt. CNN cho thấy độ chính xác lên đến 96% trong phân loại ảnh mô bệnh học Osteosarcoma [17]. U-Net giúp tự động phân vùng khối u, hỗ trợ đo thể tích và theo dõi đáp ứng điều trị [18]. GAN được sử dụng để tạo dữ liệu giả lập, giải quyết tình trạng thiếu dữ liệu huấn luyện [19]. Xu hướng mới là AI đa phương thức kết hợp hình ảnh – mô bệnh học – dữ liệu gen để dự đoán tiên lượng [20]. Tại Việt Nam, các nghiên cứu gần đây đã tích hợp AI với in 3D trong phẫu thuật bảo tồn chi, cho thấy tiềm năng ứng dụng lâm sàng cao [21].

b. Tổng kết và khoảng trống nghiên cứu

Mặc dù đã đạt được nhiều tiến bộ, lĩnh vực chẩn đoán ung thư xương bằng AI vẫn tồn tại một số hạn chế. Thứ nhất, hầu hết các mô hình hiện nay được huấn luyện trên dữ liệu quốc tế, chưa phản ánh đặc điểm giải phẫu và dịch tễ của người Việt Nam. Thứ hai, tính "hộp đen" của Deep Learning gây khó khăn cho bác sĩ trong việc tin tưởng và ra quyết định. Thứ ba, nhiều hệ thống chưa được tích hợp hoàn chỉnh vào quy trình làm việc tại bệnh viện.

Do đó, đề tài này hướng tới phát triển một hệ thống AI tự động, có khả năng giải thích, được huấn luyện trên dữ liệu phù hợp với bối cảnh Việt Nam và có tính khả thi cao trong ứng dụng lâm sàng.

3. Mục đích và nhiệm vụ nghiên cứu

a. Mục tiêu

Mục tiêu chính của đề tài là xây dựng một ứng dụng tự động và chính xác để hỗ trợ bác sĩ phát hiện ung thư xương từ các hình ảnh y tế 2D. Hệ thống này không chỉ cung cấp kết quả phân đoạn với độ chính xác cao mà còn tối ưu hóa thời gian và nguồn lực trong quá trình chẩn đoán.

b. Nhiệm vụ

Để đạt được mục tiêu trên, đề tài đặt ra các nhiệm vụ cụ thể bao gồm:

- Nghiên cứu các mô hình học sâu hiện đại, đặc biệt là U-Net và cơ chế Attention, để ứng dụng vào bài toán phân đoạn hình ảnh y tế.
- Xây dựng quy trình tiền xử lý dữ liệu như chẩn hóa hình ảnh, cắt bỏ vùng không liên quan và cân chỉnh kích thước ảnh nhằm đảm bảo dữ liệu đầu vào đạt chất lượng cao nhất và kích thước nhất định.
- Phát triển và huấn luyện mô hình trên bộ dữ liệu y tế thực tế có đáp ứng yêu cầu về tính minh bạch và bảo mật, sử dụng các thuật toán tối ưu hóa như Dice Loss và Focal Loss để cải thiện hiệu suất phân đoạn.
- Đánh giá hiệu quả mô hình thông qua các chỉ số chuyên môn, đồng thời so sánh với các phương pháp đã có để khẳng định tính vượt trội của ứng dụng.
- Đề xuất cải tiến, mở rộng khả năng ứng dụng của hệ thống.

4. Đối tượng và phạm vi nghiên cứu

a. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các hình ảnh y tế 2D, cụ thể là các ảnh X-quang hoặc CT của bệnh nhân bị nghi ngờ hoặc chẩn đoán mắc ung thư xương. Những hình ảnh này chứa thông tin quan trọng về cấu trúc xương và các vùng tổn thương, cung cấp một nền tảng dữ liệu cần thiết để phát triển hệ thống.

b. Phạm vi nghiên cứu

Nghiên cứu sẽ tập trung vào việc triển khai và tối ưu hóa mô hình U-Net, một kiến trúc mạng nơ-ron tích chập (CNN) phổ biến và hiệu quả cho các tác vụ phân đoạn ảnh y tế. Các thử nghiệm có thể bao gồm việc tích hợp U-Net vào các vùng đặc trưng quan trọng của ảnh để đánh giá khả năng cải thiện hiệu suất phân đoạn.

Không những thế, để tối ưu hóa hiệu suất phân đoạn và giải quyết vấn đề mất cân bằng lớp, nghiên cứu sẽ khảo sát việc sử dụng hàm mất mát kết hợp giữa Dice Loss và Focal Loss. Quá trình huấn luyện mô hình sẽ được thực hiện bằng thuật toán Adam, kết hợp các kỹ thuật điều chẩn như L2 regularization, Dropout

và tăng cường dữ liệu cơ bản bao gồm lật, xoay, điều chỉnh sáng/tối, tỷ lệ… để cải thiện khả năng tổng quát hóa.

Hiệu suất của mô hình sẽ được đánh giá định lượng trên tập kiểm thử thông qua các chỉ số phổ biến như Dice Coefficient, IoU, Precision và Recall, đặc biệt tập trung vào lớp khối u. Toàn bộ quá trình xây dựng, huấn luyện và đánh giá mô hình sẽ được triển khai bằng TensorFlow và Keras API, kết hợp với nền tảng Weights & Biases (WandB) để theo dõi, ghi lại và trực quan hóa các thực nghiệm.

Đề tài không chỉ dừng lại ở việc phát triển mô hình mà còn mở rộng sang việc thử nghiệm và đánh giá trên bộ dữ liệu thực tế, với kỳ vọng đưa ra được một hệ thống khả thi trong môi trường y tế tại Việt Nam.

Ngoài ra, đề tài cũng tìm hiểu các thách thức đặc thù của hình ảnh xương, như độ phức tạp của cấu trúc 2D, sự tương đồng giữa các vùng tổn thương và mô lành, để đảm bảo mô hình có thể ứng dụng hiệu quả trong thực tiễn.

5. Phương pháp nghiên cứu

Đề tài sử dụng các phương pháp nghiên cứu chính bao gồm:

- Thu thập và tiền xử lý dữ liệu: Bộ dữ liệu bao gồm các ảnh X-quang hoặc CT của bệnh nhân ung thư xương sẽ được chẩn hóa, cân chỉnh kích thước và loại bỏ các vùng không liên quan. Sau đó, đưa qua tiền xử lý dữ liệu để đảm bảo chất lượng và tính nhất quán của đầu vào.
- Phát triển mô hình: Đề tài triển khai mô hình U-Net để tận dụng cả thông tin tổng quát và chi tiết trong hình ảnh. Các thuật toán tối ưu như Dice Loss hoặc Focal Loss cũng được áp dụng trong quá trình huấn luyện để cải thiện hiệu quả phân đoạn.
- Huấn luyện và đánh giá: Mô hình sẽ được huấn luyện trên tập dữ liệu thực tế, sử dụng kỹ thuật tăng cường dữ liệu (Data Augmentation) để giảm thiểu hiện tượng overfitting. Hiệu quả mô hình được đánh giá thông qua các chỉ số chuyên môn như Dice Coefficient và IoU.
- Thử nghiệm và cải tiến: Sau khi hoàn thiện mô hình, hệ thống sẽ được thử nghiệm trên các bộ dữ liệu khác nhau để đánh giá tính ổn định và khả năng

mở rộng. Các cải tiến sẽ được đề xuất để nâng cao hiệu quả và khả năng ứng dụng thực tế.

6. Những đóng góp mới của đề tài

a. Về mặt khoa học

Đề tài góp phần mở rộng trong việc ứng dụng kết hợp U-Net vào bài toán xác định ung thư xương tại Việt Nam. Đây là một hướng đi mới, không chỉ giải quyết được những hạn chế trong phân đoạn hình ảnh y tế hiện tại mà còn mở rộng khả năng ứng dụng của học sâu vào các lĩnh vực y tế khác.

b. Về mặt thực tiễn

Về thực tiễn, đề tài này có thể hỗ trợ bác sĩ chẩn đoán nhanh chóng và chính xác, giảm tải khối lượng công việc trong các cơ sở y tế. Đồng thời, hệ thống còn tiết kiệm chi phí cho bệnh nhân thông qua việc giảm thời gian chẩn đoán và các xét nghiệm không cần thiết. Đây là một giải pháp thiết thực, góp phần nâng cao chất lượng dịch vụ y tế và thúc đẩy xu hướng số hóa y tế tại Việt Nam.

7. Cấu trúc của đề tài:

Ngoài phần mở đầu, kết luận, danh mục tài liệu tham khảo và phụ lục, nội dung chính của đề tài được triển khai thành 3 chương, trong đó mỗi chương tập trung làm rõ một khía cạnh cụ thể của vấn đề nghiên cứu, góp phần hình thành nên một hệ thống luận điểm hoàn chỉnh và logic.

Chương 1: Cơ sở lý thuyết

Chương 2: Dữ liệu và các phương pháp đề xuất

Chương 3: Kết quả thực nghiệm

PHẦN NỘI DUNG

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1. Tổng quan về ung thư xương

1.1.1. Định nghĩa

Ung thư xương là một thuật ngữ chung mô tả sự phát triển bất thường và không kiểm soát của các tế bào ác tính bắt nguồn từ mô xương hoặc sụn. Các tế bào ung thư này có khả năng xâm lấn và phá hủy các mô xương khỏe mạnh xung quanh, đồng thời có thể di căn đến các bộ phận khác của cơ thể .

Ung thư xương được phân thành hai nhóm chính:

- Ung thư xương nguyên phát: khi khối u khởi phát trực tiếp từ các tế bào xương hoặc sụn. Ví dụ như Osteosarcoma (ung thư xương tạo xương), Chondrosarcoma (ung thư sụn), Ewing sarcoma (u xương Ewing), Fibrosarcoma và Malignant Fibrous Histiocytoma (sarcoma sợi và u sợi bào ác tính).
- Ung thư xương thứ phát (hay còn gọi là di căn xương): khi các tế bào ung thư từ một cơ quan khác (như phổi, vú, tuyến tiền liệt) lan đến xương và hình thành khối u mới.

Việc phân loại chính xác loại ung thư xương là vô cùng quan trọng, vì nó ảnh hưởng trực tiếp đến tiên lượng và lựa chọn phương pháp điều trị cho bệnh nhân.

1.1.2. Nguyên nhân và tỷ lệ mắc bệnh ung thư xương

1.1.2.1. Nguyên nhân gây ra ung thư xương

Cho đến nay, nguyên nhân chính gây ra hầu hết các trường hợp ung thư xương vẫn chưa được xác định rõ ràng. Tuy nhiên, một số yếu tố nguy cơ đã được ghi nhận có thể làm tăng khả năng mắc bệnh, bao gồm:

- Yếu tố di truyền (ví dụ: một số hội chứng di truyền như hội chứng Li-Fraumeni, retinoblastoma di truyền).
- Do ảnh hưởng hoặc tiếp xúc với môi trường hóa chất và bức xạ.

- Tiền sử xạ trị hoặc hóa trị liệu cho các bệnh ung thư khác.
- Một số bệnh lý xương lành tính như bệnh Paget xương và chấn thương xương mạn tính (mặc dù mối liên hệ này còn gây tranh cãi).

Ung thư xương nguyên phát là một loại ung thư tương đối hiếm gặp, chiếm một tỷ lệ nhỏ trong tổng số các ca ung thư được chẩn đoán hàng năm. Tỷ lệ mắc bệnh có thể thay đổi tùy theo độ tuổi, giới tính và chủng tộc, với một số loại như Osteosarcoma thường gặp hơn ở trẻ em và thanh thiếu niên, trong khi Chondrosarcoma lại phổ biến hơn ở người lớn tuổi. Ngược lại, ung thư xương thứ phát (di căn xương) lại phổ biến hơn nhiều, do nhiều loại ung thư ở các cơ quan khác có xu hướng di căn đến xương.

1.1.2.2. Tỷ lệ mắc bệnh ung thư xương

Ung thư xương là một bệnh hiếm gặp, chiếm một tỷ lệ nhỏ trong tổng số các ca ung thư được chẩn đoán hàng năm. Tỷ lệ mắc bệnh có thể thay đổi tùy theo độ tuổi, giới tính và chủng tộc. Tỷ lệ mắc ung thư xương nguyên phát trên toàn cầu dao động từ 1-3 ca trên mỗi triệu người mỗi năm, trong đó phổ biến nhất là các dạng như osteosarcoma, chondrosarcoma, và Ewing sarcoma. Một số loại như Osteosarcoma thường bắt gặp ở trẻ em và thanh thiếu niên ở nhóm tuổi từ 10-20, trong khi Chondrosarcoma lại phổ biến hơn ở người lớn tuổi.

Ngược lại, ung thư xương thứ phát (di căn xương) lại phổ biến hơn nhiều, do nhiều loại ung thư ở các cơ quan khác có xu hướng di căn đến xương. Đặc biệt, theo thống kê từ tạp chí Cancer 2009, nam giới có nguy cơ mắc bệnh cao hơn nữ giới, với tỷ lệ nam:nữ khoảng 1,35:1.

1.2. Học sâu trong chẩn đoán ung thư xương

Chẩn đoán hình ảnh y tế, bao gồm các kỹ thuật như X-quang, CT, MRI, đóng vai trò không thể thiếu trong y học hiện đại, cung cấp thông tin trực quan quý giá cho việc phát hiện, chẩn đoán, theo dõi và lập kế hoạch điều trị nhiều loại bệnh lý, đặc biệt là ung thư. Tuy nhiên, do khối lượng dữ liệu hình ảnh ngày càng tăng cùng với sự phức tạp của các dấu hiệu bệnh lý đã đặt ra thách thức lớn cho các chuyên

gia y tế về thời gian và độ chính xác. Để giải quyết những thách thức này, học sâu (Deep Learning) là cộng sự đầy tiềm năng.

1.2.1. Tổng quan về học sâu

Học sâu hay còn gọi là Deep Learning là một nhánh thuộc lĩnh vực trí tuệ nhân tạo, phát triển từ Machine Learning với nền tảng là các mạng nơ-ron nhân tạo (Artificial Neural Networks - ANN). Đây là phương pháp học máy có khả năng học biểu diễn dữ liệu thông qua nhiều lớp trừu tượng hóa, cho phép máy tính tự động trích xuất đặc trưng mà không cần đến các kỹ thuật thủ công trong thiết kế đặc trưng như các phương pháp truyền thống.

Điểm đặc biệt của Deep Learning là khả năng xử lý dữ liệu lớn (Big Data) nhờ vào sự hỗ trợ của phần cứng mạnh mẽ như GPU, đặc biệt là sau sự xuất hiện của dòng GPU GTX 10 series từ NVIDIA. Điều này giúp tăng tốc độ huấn luyện và mở rộng khả năng ứng dụng của Deep Learning từ phòng thí nghiệm ra thực tiễn. Sự thành công vang dội của mô hình AlexNet năm 2012 tại cuộc thi ILSVRC (ImageNet Large Scale Visual Recognition Challenge) đã đánh dấu bước ngoặt cho Deep Learning khi lần đầu tiên mô hình mạng nơ-ron nhân tạo đạt được kết quả vượt trội so với các phương pháp truyền thống trong nhận diện hình ảnh .

Deep Learning đã chứng minh tính ứng dụng rộng rãi của mình trong nhiều lĩnh vực như thị giác máy tính (computer vision), xử lý ngôn ngữ tự nhiên (natural language processing), nhận diện giọng nói, y tế, giao thông, và nhiều lĩnh vực khác trong cuộc sống. Và trong đề tài này, Deep Learning cúng đóng một vai trò quan trọng, bằng cách tự động học các đặc trưng phức tạp từ dữ liệu hình ảnh y tế, các mô hình học sâu có thể hỗ trợ đắc lực cho bác sĩ trong việc phát hiện sớm các tổn thương nhỏ, phân đoạn chính xác các vùng quan tâm, phân loại bệnh lý và thậm chí dự đoán tiên lượng, qua đó hứa hẹn cải thiện đáng kể chất lượng chăm sóc sức khỏe và hiệu quả chẩn đoán.

1.2.2. Nguyên lý cơ bản và mạng nơ-ron trong học sâu

Học sâu là một lĩnh vực con của học máy, tập trung vào việc xây dựng và huấn luyện các mạng nơ-ron nhân tạo (Artificial Neural Networks - ANNs) với nhiều lớp ẩn để học các biểu diễn dữ liệu phức tạp và thực hiện các tác vụ dự đoán hoặc ra quyết định.

Khác với các phương pháp học máy truyền thống thường đòi hỏi quá trình thiết kế và trích xuất đặc trưng thủ công tốn nhiều công sức bởi các chuyên gia, học sâu có khả năng tự động học các đặc trưng phân cấp trực tiếp từ dữ liệu thô. Các lớp gần đầu vào của mạng ANN học các đặc trưng ở mức độ thấp (ví dụ: cạnh, góc trong hình ảnh), trong khi các lớp sâu hơn kết hợp các đặc trưng này để học các khái niệm trừu tượng và phức tạp hơn.

Nguyên lý hoạt động cốt lõi dựa trên việc tối ưu hóa các tham số như trọng số và độ lệch của mạng thông qua một thuật toán, thường là lan truyền ngược (backpropagation) và các biến thể của gradient descent, nhằm giảm thiểu sự khác biệt giữa đầu ra dự đoán và giá trị thực tế của dữ liệu huấn luyện, được đo lường bằng một hàm mất mát (loss function).

1.2.3. Kiến trúc mạng nơ-ron tích chập – CNN

Mạng nơ-ron tích chập hay còn gọi là Convolutional Neural Network là một lớp kiến trúc mạng nơ-ron sâu chuyên biệt, đạt được thành công vang dội trong các bài toán liên quan đến dữ liệu có cấu trúc dạng lưới, đặc biệt là hình ảnh. Đặc điểm nổi bật của CNN là việc sử dụng các lớp tích chập - convolutional layers để tự động học các bộ lọc filters hoặc kernels có khả năng phát hiện các đặc trưng không gian cục bộ trong ảnh, chẳng hạn như cạnh, góc, kết cấu ở các lớp nông và các đối tượng hay bộ phận phức tạp hơn ở các lớp sâu hơn. Các lớp tích chập thường đi kèm với pooling layers, ví dụ: max pooling giúp giảm kích thước không gian của bản đồ đặc trưng, tăng tính bất biến với các thay đổi nhỏ về vị trí và giảm số lượng tham số tính toán. Cuối cùng, các đặc trưng được học thường được đưa qua một hoặc nhiều lớp kết nối đầy đủ (fully connected layers) để thực hiện nhiệm vụ phân loại hoặc hồi quy.

Một số kiến trúc CNN mang tính bước ngoặt đã định hình sự phát triển của lĩnh vực này. LeNet-5 là một trong những CNN đầu tiên thành công trong nhận dạng chữ số viết tay. AlexNet với kiến trúc sâu hơn và việc sử dụng GPU đã giành chiến thắng thuyết phục trong cuộc thi ImageNet, đánh dấu sự trỗi dậy mạnh mẽ của học sâu.

Sau đó, các kiến trúc như VGGNet với các bộ lọc nhỏ 3x3 xếp chồng lên nhau, GoogLeNet với module "Inception" và ResNet với các kết nối tắt - residual connections cho phép huấn luyện các mạng rất sâu đã liên tục đẩy lùi giới hạn về độ chính xác trong các tác vụ thị giác máy tính. Mặc dù nghiên cứu này tập trung vào U-Net, việc hiểu các nguyên lý thiết kế từ những kiến trúc nền tảng này là rất hữu ích.

1.2.4. Học sâu trong y học và chẩn đoán hình ảnh ý tế

1.2.4.1. Ứng dụng của học sâu trong y học

Học sâu đã và đang tạo ra những thay đổi mang tính cách mạng trong nhiều khía cạnh của y học và chăm sóc sức khỏe, vượt ra ngoài lĩnh vực phân tích hình ảnh. Một trong những ứng dụng nổi bật là trong lĩnh vực gen và proteomics, nơi các mô hình học sâu được sử dụng để dự đoán cấu trúc protein, xác định các biến thể gen liên quan đến bệnh tật, và phân tích dữ liệu biểu hiện gen để hiểu rõ hơn về cơ chế bệnh sinh. Trong phát triển thuốc, học sâu hỗ trợ việc sàng lọc các hợp chất tiềm năng, dự đoán độc tính và hiệu quả của thuốc, và thậm chí thiết kế các phân tử thuốc mới, qua đó rút ngắn đáng kể thời gian và chi phí nghiên cứu.

Ngoài ra, học sâu còn được ứng dụng trong việc phân tích hồ sơ bệnh án điện tử (EHR) để dự đoán nguy cơ mắc bệnh, phát hiện sớm các đợt bệnh cấp tính, tối ưu hóa phác đồ điều trị và hỗ trợ các quyết định lâm sàng dựa trên bằng chứng từ lượng lớn dữ liệu bệnh nhân. Các ứng dụng khác bao gồm robot phẫu thuật được tăng cường bởi AI, hệ thống theo dõi sức khỏe cá nhân thông minh và phát hiện các mẫu bất thường trong tín hiệu sinh lý như điện tâm đồ (ECG) hay điện não đồ (EEG).

1.2.4.2. Vai trò của học sâu trong chẩn đoán hình ảnh ý tế

Lĩnh vực chẩn đoán hình ảnh y tế có lẽ là nơi học sâu thể hiện rõ rệt nhất tiềm năng biến đổi của mình. Việc phân tích hình ảnh y tế truyền thống thường dựa vào kinh nghiệm và khả năng nhận diện mẫu của các bác sĩ x-quang, một quá trình có thể bị ảnh hưởng bởi sự mệt mỏi, khối lượng công việc lớn và tính chủ quan nhất định, dẫn đến nguy cơ bỏ sót hoặc chẩn đoán không nhất quán. Các mô hình học

sâu, đặc biệt là CNN, có khả năng tự động học các đặc trưng hình ảnh phức tạp liên quan đến bệnh lý trực tiếp từ dữ liệu, giúp giải quyết nhiều thách thức này.

Trong phát hiện bệnh, các thuật toán học sâu có thể được huấn luyện để xác định sự hiện diện của các dấu hiệu bất thường như khối u, nốt phổi, xuất huyết não, hay gãy xương với độ nhạy và độ đặc hiệu cao, đôi khi tương đương hoặc vượt trội so với chuyên gia con người trong một số tác vụ cụ thể.

Trong phân loại bệnh lý, học sâu hỗ trợ việc phân biệt giữa các tình trạng khác nhau dựa trên đặc điểm hình ảnh, ví dụ như phân biệt khối u lành tính và ác tính, hoặc xác định các giai đoạn khác nhau của bệnh. Đối với bài toán phân đoạn ảnh, một trọng tâm của nghiên cứu này, các mô hình học sâu như U-Net có khả năng khoanh vùng chính xác các cơ quan, mô hoặc tổn thương bệnh lý, cung cấp thông tin định lượng về kích thước, hình dạng, thể tích, điều này rất quan trọng cho việc lập kế hoạch phẫu thuật, xạ trị, và theo dõi đáp ứng điều trị. Có thể thấy, học sâu có khả năng xử lý lượng lớn hình ảnh một cách nhanh chóng và nhất quán không chỉ giúp giảm tải cho các chuyên gia y tế mà còn hứa hẹn cải thiện khả năng tiếp cận các dịch vụ chẩn đoán chất lượng cao, đặc biệt ở những khu vực thiếu hụt nhân lực y tế.

1.3. Kỹ thuật học sâu trong chẩn đoán ảnh y tế

Phân đoạn ảnh y tế là quá trình phân chia một hình ảnh y tế thành nhiều vùng hoặc đối tượng có ý nghĩa, trong đó mỗi pixel trong ảnh được gán cho một nhãn lớp cụ thể. Mục tiêu của phân đoạn có thể là để xác định ranh giới chính xác của các cơ quan giải phẫu, ví dụ như não, tim, gan…, các cấu trúc mô bệnh học, ví dụ như tế bào ung thư, hoặc các vùng tổn thương bệnh lý, ví dụ như khối u…

Kết quả phân đoạn cung cấp thông tin định lượng và không gian quan trọng, hỗ trợ đắc lực cho nhiều ứng dụng lâm sàng như chẩn đoán bệnh, đánh giá mức độ nghiêm trọng, lập kế hoạch can thiệp phẫu thuật hoặc xạ trị, theo dõi sự phát triển của bệnh hoặc đáp ứng với điều trị. Ví dụ, trong nghiên cứu ung thư, việc phân đoạn chính xác khối u cho phép đo lường thể tích và theo dõi sự thay đổi kích thước của nó theo thời gian. Đây là một chỉ số quan trọng để đánh giá hiệu quả của phác đồ điều trị.

Tuy nhiên, phân đoạn ảnh y tế là một bài toán đầy thách thức do nhiều yếu tố, chẳng hạn như hình ảnh y tế thường có độ tương phản thấp giữa các mô khác nhau, ranh giới giữa các cấu trúc có thể mờ nhạt hoặc không rõ ràng, sự hiện diện của nhiễu và các tạo ảnh (artifacts) do quá trình thu nhận hình ảnh, cũng như sự đa dạng lớn về hình dạng, kích thước và vị trí của các cấu trúc giải phẫu hoặc tổn thương giữa các bệnh nhân khác nhau. Hơn nữa, việc thu thập dữ liệu gán nhãn ở cấp độ pixel (ground truth masks) cho việc huấn luyện các mô hình phân đoạn đòi hỏi nhiều thời gian và công sức từ các chuyên gia y tế. Các phương pháp phân đoạn truyền thống dựa trên ngưỡng, phát hiện biên, hay phát triển vùng thường gặp khó khăn với những thách thức này.

Do đó, sự ra đời của các mô hình học sâu, đặc biệt là các kiến trúc dựa trên mạng nơ-ron tích chập, đã mang lại những tiến bộ đáng kể trong việc giải quyết bài toán phân đoạn ảnh y tế một cách tự động và chính xác hơn.

1.4. U-Net trong phân đoạn ảnh y tế

1.4.1. Kiến trúc và nguyên lý hoạt động của U-Net

U-Net, được giới thiệu bởi Ronneberger và cộng sự vào năm 2015 , là một kiến trúc mạng nơ-ron tích chập được thiết kế chuyên biệt cho các tác vụ phân đoạn ảnh y sinh và đã nhanh chóng trở thành một trong những kiến trúc nền tảng và được sử dụng rộng rãi nhất trong lĩnh vực này. Kiến trúc của U-Net có dạng đối xứng hình chữ U, bao gồm hai thành phần chính: đường đi xuống – contracting path hoặc encoder và đường đi lên – expanding path hoặc decoder. Đường đi xuống có cấu trúc tương tự như một mạng CNN phân loại điển hình, bao gồm các khối lặp lại của hai lớp tích chập 3x3 không đệm – unpadded convolutions, theo sau bởi một hàm kích hoạt ReLU và một lớp gộp cực đại – max pooling 2x2 với sải bước 2. Mục đích của đường đi xuống là để giảm dần kích thước không gian của bản đồ đặc trưng (feature map) trong khi tăng số lượng kênh đặc trưng. Qua đó giúp nắm bắt thông tin ngữ cảnh và các đặc trưng trừu tượng của ảnh đầu vào.

Đường đi lên – decoder, thực hiện nhiệm vụ ngược lại: tăng dần độ phân giải không gian của bản đồ đặc trưng để tạo ra một mặt nạ phân đoạn có cùng kích thước với ảnh đầu vào. Điều này thường đạt được thông qua việc sử dụng các lớp

giải tích chập – transposed convolution hoặc up-convolution 2x2, làm tăng gấp đôi kích thước không gian và giảm một nửa số kênh đặc trưng. Một đặc điểm then chốt và mang tính đột phá của U-Net là skip connections. Các kết nối này sao chép và ghép nối – concatenate các bản đồ đặc trưng có độ phân giải cao từ đường đi xuống với các bản đồ đặc trưng tương ứng đã được giải tích chập ở đường đi lên. Nhờ các kết nối tắt này, thông tin không gian chi tiết bị mất trong quá trình gộp ở đường đi xuống có thể được phục hồi và kết hợp với thông tin ngữ cảnh cấp cao được học ở các lớp sâu hơn, cho phép mô hình định vị chính xác ranh giới của các đối tượng cần phân đoạn. Lớp cuối cùng của mạng thường là một lớp tích chập 1x1 sử dụng hàm kích hoạt Sigmoid hoặc Softmax để tạo ra bản đồ xác suất cho từng pixel thuộc về mỗi lớp.

1.4.2. Lợi thế của U-Net trong phân đoạn ảnh

Kiến trúc U-Net ban đầu được thiết kế và chứng minh hiệu quả cho các tác vụ phân đoạn trên ảnh y tế 2D, nơi nó có khả năng phân tích từng lát cắt riêng lẻ của dữ liệu. Một trong những lợi thế lớn của U-Net là khả năng hoạt động tốt ngay cả khi tập dữ liệu huấn luyện có kích thước hạn chế. Đây là một trong những tình huống thường gặp trong y tế. Skip connections cho phép truyền tải hiệu quả thông tin chi tiết, giúp U-Net phân đoạn chính xác các cấu trúc phức tạp và có ranh giới tinh vi.

Hơn thế nữa, U-Net có thể được huấn luyện từ đầu – end-to-end và tương đối dễ triển khai so với một số kiến trúc phức tạp khác. Khả năng xử lý ảnh 2D của U-Net phù hợp với nhiều loại dữ liệu y tế như ảnh X-quang, lát cắt CT.

1.5. Các công nghệ và framework

1.5.1. Giới thiệu về PyTorch

PyTorch là một thư viện học máy mã nguồn mở dựa trên Torch, được phát triển bởi phòng nghiên cứu AI của Meta. Kể từ khi ra mắt năm 2016, PyTorch nhanh chóng trở nên phổ biến nhờ tính linh hoạt, giao diện Python trực quan và khả năng gỡ lỗi hiệu quả. Một đặc điểm nổi bật của PyTorch là việc sử dụng đồ thị tính toán động "define-by-run", cho phép thay đổi cấu trúc mạng trong quá trình thực thi – rất hữu ích cho các mô hình phức tạp như RNN.

PyTorch có thư viện cung cấp các tensor tính toán trên GPU, module autograd để tự động tính đạo hàm, cùng các công cụ xây dựng và huấn luyện mạng nơ-ron như torch.nn, torch.optim. PyTorch cũng có hệ sinh thái phong phú gồm torchvision, torchaudio, torchtext, và hỗ trợ triển khai mô hình qua TorchScript hoặc ONNX.

Chính nhờ sự linh hoạt và hỗ trợ mạnh mẽ này, PyTorch trở thành nền tảng lý tưởng để xây dựng, huấn luyện và đánh giá các mô hình phân đoạn ảnh y tế như U-Net và Attention U-Net trong nghiên cứu này.

1.5.2. Giới thiệu về MONAI

MONAI hay còn gọi là Medical Open Network for AI là một framework mã nguồn mở dựa trên PyTorch, được phát triển nhằm thúc đẩy ứng dụng trí tuệ nhân tạo trong lĩnh vực ảnh y tế. MONAI cung cấp một bộ công cụ toàn diện và chẩn hóa cho toàn bộ quy trình phát triển mô hình AI y tế – từ tải và tiền xử lý dữ liệu, tăng cường dữ liệu, xây dựng và huấn luyện mô hình, đến đánh giá và triển khai.

Framework này đặc biệt phù hợp với dữ liệu y tế nhờ hỗ trợ nhiều định dạng như DICOM, NIfTI, dữ liệu đa chiều từ 2D, 3D đến 4D và các phép biến đổi chuyên biệt như biến đổi hình học bảo toàn cấu trúc hoặc điều chỉnh cường độ theo từng modality. MONAI tích hợp sẵn nhiều kiến trúc mạng phổ biến (U-Net, V-Net, DenseNet3D), hàm mất mát, chỉ số đánh giá, cùng các pipeline huấn luyện mẫu tối ưu hóa sẵn.

Nhờ sự kết hợp giữa tính linh hoạt của PyTorch và các tính năng chuyên biệt cho y tế, MONAI giúp rút ngắn thời gian phát triển, tăng tính tái lặp và hỗ trợ chia sẻ, hợp tác hiệu quả trong nghiên cứu AI y tế.

1.5.3. PyTorch Lightning

PyTorch Lightning là một thư viện mã nguồn mở cấp cao, bao bọc PyTorch nhằm chẩn hóa quy trình huấn luyện mô hình học sâu. Thư viện này giúp tách biệt rõ ràng phần logic mô hình bao gồm kiến trúc mạng, hàm mất mát, thuật toán tối ưu, tính toán metrics, tách khỏi các thao tác kỹ thuật như vòng lặp huấn luyện, phân phối tính toán hay logging. Tất cả đều được đóng gói trong lớp LightningModule.

Lightning tự động xử lý nhiều khâu trong huấn luyện như di chuyển dữ liệu lên GPU, lan truyền ngược, cập nhật trọng số, hỗ trợ huấn luyện với mixed precision, phân tán trên nhiều GPU hoặc máy và tích hợp logging với TensorBoard hoặc Weights & Biases. Nhờ đó, người dùng có thể tập trung phát triển mô hình, giảm lặp lại code, tăng tính tái sử dụng và mở rộng quy mô dễ dàng.

Với thiết kế rõ ràng và hiệu quả, PyTorch Lightning là công cụ hữu ích trong nghiên cứu và triển khai các mô hình học sâu phức tạp, giúp tăng năng suất và đảm bảo tính tái lặp trong các thí nghiệm.

1.6. Các nghiên cứu liên quan

1.6.1. Ứng dụng cơ chế chú ý và dung hợp đa tỷ lệ vào mô hình YOLO

Trong một nghiên cứu gần đây, Chen và cộng sự (2025) đã đề xuất mô hình YOLOv11-MTB [22] nhằm giải quyết những hạn chế trong việc phát hiện sớm các khối u xương nguyên phát (như ung thư xương và ung thư sụn) có kích thước nhỏ hoặc đa ổ trên ảnh chụp X-quang. Nhận thấy các phiên bản YOLO trước đây thường gặp khó khăn do trường tiếp nhận (receptive field) cố định và thiếu cơ chế kết hợp đặc trưng đa tỷ lệ hiệu quả, nhóm tác giả đã cải tiến kiến trúc YOLOv11 bằng cách tích hợp cơ chế chú ý nhân chập lớn (large kernel attention), chú ý dựa trên Transformer đa tỷ lệ và dung hợp đặc trưng nhận thức biên (boundary-aware feature fusion). Đánh giá trên bộ dữ liệu đa trung tâm BTXRD cho thấy YOLOv11-MTB đạt hiệu suất vượt trội với độ chính xác trung bình (mAP) đạt 79,6%. Đặc biệt, mô hình đã thành công trong việc giảm tỷ lệ bỏ sót các tổn thương nhỏ từ 43% (của YOLOv8) [1] xuống chỉ còn 22%, đồng thời đạt mAP 55,8% đối với tổn thương nhỏ và 63,2% đối với tổn thương đa ổ, qua đó chứng minh tiềm năng ứng dụng thực tiễn to lớn của mô hình trong hỗ trợ chẩn đoán lâm sàng.

1.6.2. Tự động hóa phát hiện và phân loại u xương vùng đầu gối trên ảnh X-quang

Trong nỗ lực tự động hóa quá trình chẩn đoán khối u xương vùng đầu gối trên ảnh X-quang, Do và cộng sự [6] đã đề xuất mô hình đa cấp độ Seg-Unet kết hợp giữa phương pháp tiếp cận toàn cục (global) và cục bộ theo từng vùng ảnh

(patch-based). Khác với các nghiên cứu trước đó, mô hình này được thiết kế với kiến trúc mã hóa - giải mã (encoder-decoder) thực hiện đồng thời ba tác vụ: phân loại khối u (bình thường, lành tính, ác tính), phân vùng khối u và phân vùng các khu vực rủi ro cao. Phương pháp toàn cục giúp mạng học được ngữ cảnh hình học tổng thể của xương khớp gối, trong khi phương pháp theo vùng ảnh (patch-based) tập trung tinh chỉnh trên các khối ảnh nhỏ để khắc phục những thách thức về kích thước nhỏ và sự đa dạng hình thái của các tổn thương ác tính. Thử nghiệm trên bộ dữ liệu thực tế do Bệnh viện Đại học Quốc gia Chonnam (Hàn Quốc) cung cấp cho thấy phương pháp này đạt độ chính xác phân loại lên tới 99,05% và độ giao thoa trung bình (Mean IoU) trong phân vùng đạt 84,84%. Kết quả này khẳng định hiệu quả của việc kết hợp học đa tác vụ (multi-task learning) và trích xuất đặc trưng đa cấp độ trong việc hỗ trợ các bác sĩ phát hiện sớm và chính xác u xương đầu gối.

1.6.3. Kết luận

Từ các nghiên cứu đã được công bố, có thể khẳng định rằng học sâu, đặc biệt là các kiến trúc mạng nơ-ron tích chập (CNN), đã chứng minh được hiệu quả vượt trội trong việc phân tích và xử lý ảnh y tế. Các mô hình như U-Net và các biến thể của nó đóng vai trò quan trọng trong bài toán phân đoạn tổn thương, trong khi các mạng CNN sâu giúp cải thiện khả năng phân loại và phát hiện bệnh.

Tuy nhiên, việc ứng dụng các phương pháp này trong chẩn đoán ung thư xương vẫn còn nhiều thách thức, đặc biệt là vấn đề dữ liệu hạn chế, sự đa dạng về hình thái khối u và sự mất cân bằng giữa vùng tổn thương và nền ảnh. Do đó, việc tiếp tục nghiên cứu và tối ưu các mô hình học sâu, kết hợp với các kỹ thuật tiền xử lý và tăng cường dữ liệu, là hướng đi cần thiết để nâng cao hiệu quả của các hệ thống hỗ trợ chẩn đoán tự động.

Trong bối cảnh đó, đề tài này tập trung nghiên cứu và phát triển mô hình học sâu nhằm phát hiện và phân đoạn khối u xương từ ảnh X-quang, góp phần bổ sung thêm bằng chứng thực nghiệm cho việc ứng dụng trí tuệ nhân tạo trong lĩnh vực chẩn đoán hình ảnh y khoa.

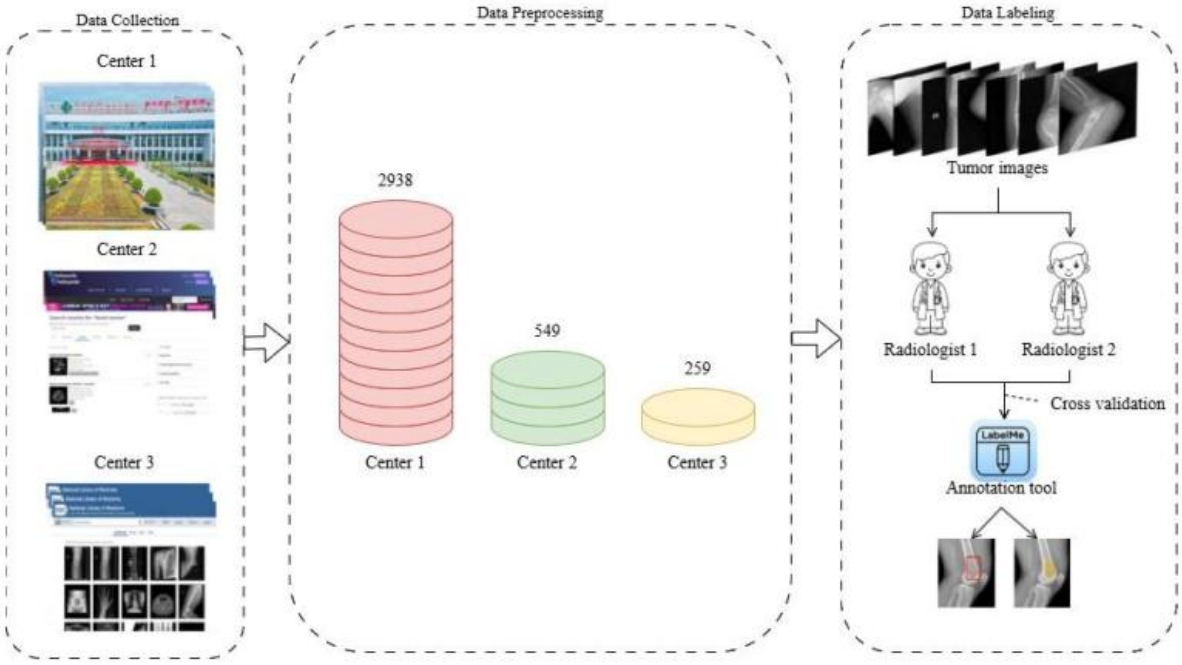
CHƯƠNG 2: DỮ LIỆU VÀ CÁC PHƯƠNG PHÁP ĐỀ XUẤT

2.1. Phân tích và chuẩn bị dữ liệu

2.1.1. Nguồn dữ liệu

Đề tài sử dụng bộ dữ liệu BTXRD, hay còn gọi là Bone Tumor X-ray Radiograph Dataset. Đây là một tập dữ liệu miễn phí được chia sẻ trên Figshare [1], phục vụ cộng đồng nghiên cứu xây dựng các hệ thống học sâu phục vụ chẩn đoán, phân tích bức ảnh X-quang xương. Bộ dữ liệu có kích thước 801 MB, với 3.746 ảnh X-quang cùng tệp ghi chú và thông tin tổng hợp. Bộ dữ liệu có cấu trúc gồm có ba thành phần chính: thư mục "images" chứa các ảnh X-quang, thư mục "Annotations" chứa tệp chú thích định dạng JSON mô tả vùng tổn thương, và tệp "dataset.csv" cung cấp thông tin tổng quan cho toàn bộ tập dữ liệu.

Dữ liệu được thu thập từ ba nguồn chính. Nguồn đầu tiên được lấy từ bệnh viện tại Trung Quốc. Thứ hai là nền tảng Radiopaedia.org và nguồn thứ 3 là từ cơ sở dữ liệu MedPix. Mỗi loại tổn thương được chụp ở nhiều góc độ khác nhau nhằm tăng độ đa dạng của dữ liệu đầu vào. Quy trình thu thập dữ liệu được minh họa trong Hình 2. 1, bao gồm các bước thu thập dữ liệu, tiền xử lý dữ liệu và gán nhãn chú thích cho các vùng khối u xương.



Hình 2. 1. Quy trình thiết kế tập dữ liệu BTXRD

Sau khi xử lý bộ dữ liệu, chúng tôi thống kê thông tin bộ BTXRD như Bảng 2. 1 sau:

Bảng 2. 1. Đặc điểm cơ bản của tập dữ liệu BTXRD

BTXRD	Age (y)	Gender (M/F)	Normal	Benign tumor	Malignant tumor	Total
Center 1	40.36 ± 19.23	1600/1338	1593	1110	235	2938
Center 2	22.32 ±14.57	326/223	259	214	76	549
Center 3	22.58 ±13.75	172/87	27	201	31	259
Total	37.53 ±19.58	2098/1648	1879	1525	342	3746

2.1.2. Thống kê đặc điểm dữ liệu

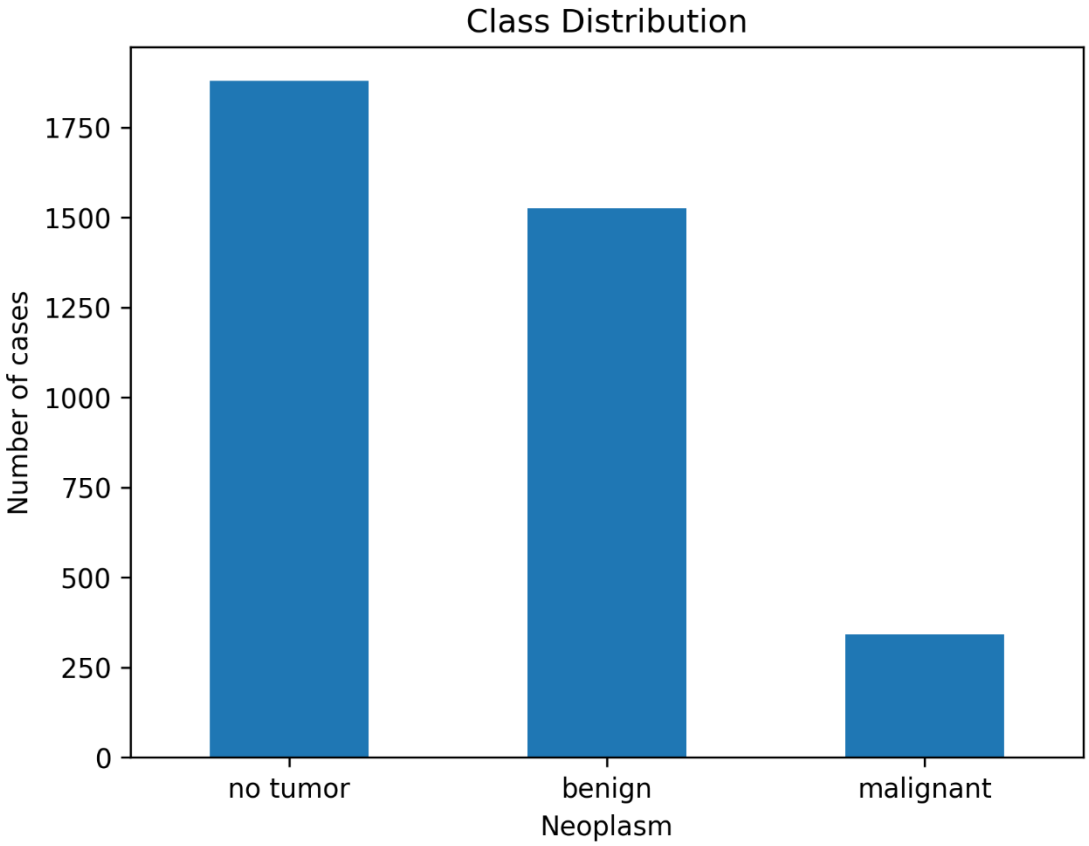
Tổng cộng bộ dữ liệu bao gồm 3.746 hình ảnh. Việc phân tích sâu các đặc điểm thống kê giúp nhận diện các thách thức kỹ thuật (như mất cân bằng dữ liệu) để đề xuất giải pháp xử lý phù hợp.

2.1.2.1. Phân bố theo lớp bệnh lý (Class Distribution)

Dữ liệu được chia thành 3 nhóm nhãn chính, được thể hiện trực quan tại Hình 2. 2:

- Xương bình thường (Normal): 1.879 ảnh.
- U lành tính (Benign): 1.525 ảnh.
- U ác tính (Malignant): 342 ảnh.

Nhận xét: Có sự mất cân bằng dữ liệu (Data Imbalance) rõ rệt giữa nhóm Lành tính và Ác tính (tỷ lệ xấp xỉ 4.5:1). Điều này phản ánh đúng thực tế lâm sàng (u ác tính hiếm gặp hơn), nhưng đặt ra thách thức lớn cho mô hình AI. Nếu không xử lý, mô hình sẽ có xu hướng dự đoán thiên lệch về nhóm đa số (Lành tính).



Hình 2. 2. Biểu đồ cột thống kê dữ liệu theo phân loại bệnh lý

2.1.2.2. Đặc điểm nhân khẩu học (Demographics)

Dựa trên tệp dữ liệu classification.xlsx, các chỉ số nhân khẩu học được thống kê chi tiết như sau:

- Độ tuổi: Độ tuổi trung bình của mẫu là 35.29 ± 20.90. Độ lệch chuẩn lớn cho thấy dải tuổi trải rộng từ nhi khoa đến lão khoa, bao phủ được các loại u đặc thù theo lứa tuổi.
- Giới tính: Tỷ lệ Nam/Nữ là 2098/1648, tương đối cân bằng, giúp mô hình tránh được các thiên kiến (bias) về giới tính.

2.1.2.3. Phân bố theo vị trí giải phẫu (Anatomical Distribution)

Dựa theo Bảng 2. 2: Phân tích vị trí tổn thương cho thấy ung thư chủ yếu tập trung tại các xương dài chịu lực, cụ thể:

- Nhóm phổ biến: Xương chày (Tibia - 624 ảnh) và Xương đùi (Femur - 477 ảnh) chiếm tỷ trọng cao nhất. Điều này phù hợp với quy luật y học:

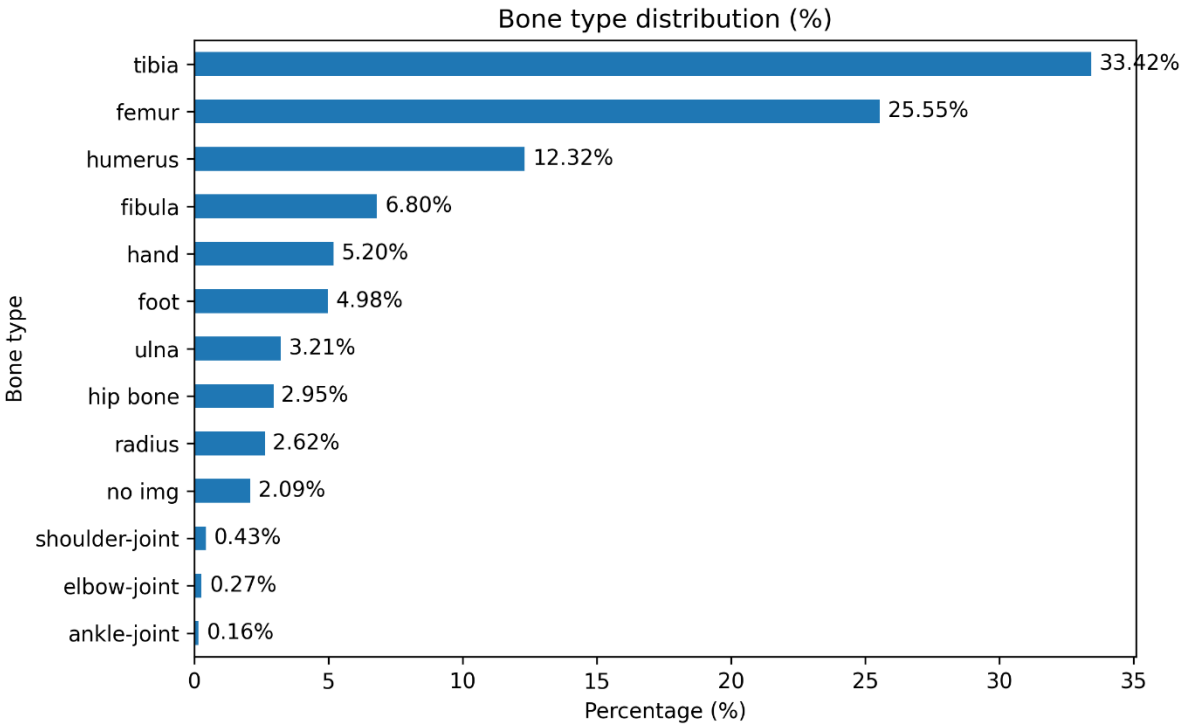
vùng quanh gối (đầu dưới xương đùi, đầu trên xương chày) là nơi sụn tăng trưởng hoạt động mạnh nhất, do đó có nguy cơ phát sinh u cao nhất.

– Nhóm hiếm gặp: Các vị trí như khớp cổ chân (3 ảnh) hay khớp vai (8 ảnh) có số lượng mẫu rất hạn chế.

Bảng 2. 2. Bảng thống kê số lượng ảnh theo vị trí tổn thương

bones_type	Count of bones_type
ankle-joint	3
elbow-joint	5
ftôiur	477
fibula	127
foot	93
hand	97
hip bone	55
humerus	230
radius	49
shoulder-joint	8
tibia	624
ulna	60

Kết hợp với Hình 2. 3 để làm rõ tỉ lệ ung thư ở các vị trí xương khác nhau. Trong đó tibia (xương chày) chiếm tỉ lệ cao nhất 33,42%. Và ankle-joint (xương cổ chân) chiếm tỉ lệ thấp nhất 0,16%.

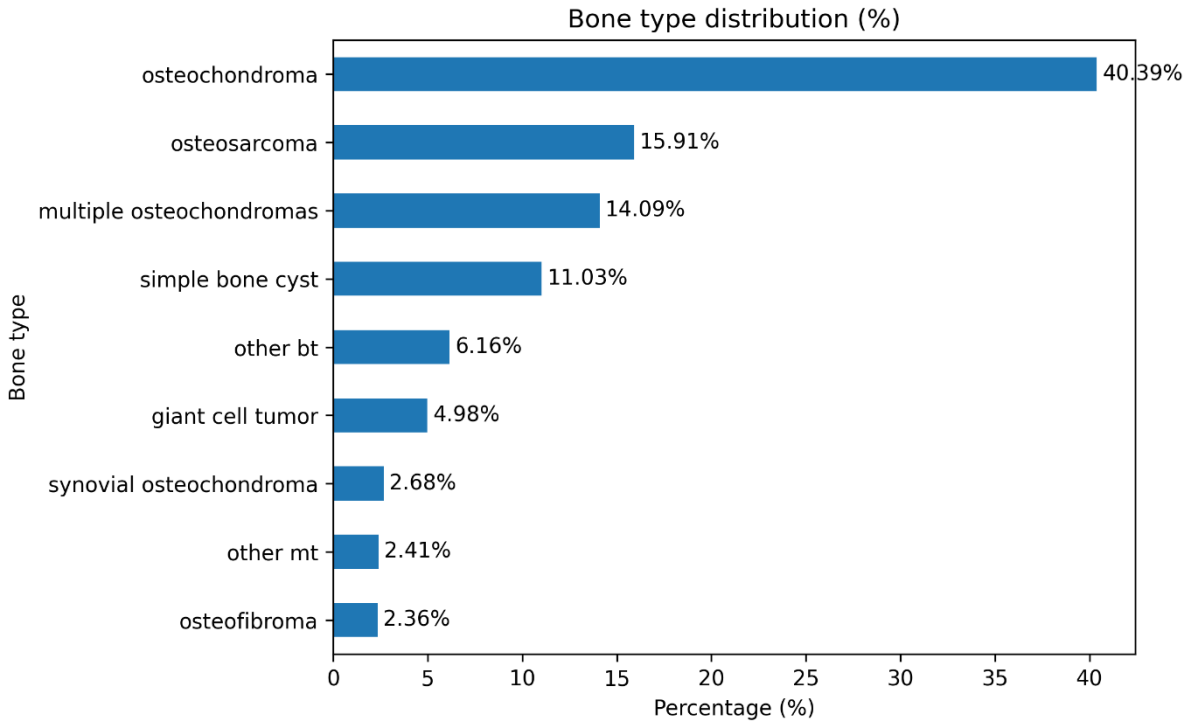


Hình 2. 3. Biểu đồ thống kê tỉ lệ ung thư tại các vị trí xương

2.1.2.3. Phân bố chi tiết theo loại bệnh lý (Pathological Types)

Sự đa dạng sinh học của các khối u được thống kê trong Hình 2. 4:

- Osteochondroma (U xương sụn): Là loại u lành tính phổ biến nhất với 754 ảnh. Đặc điểm hình ảnh là các chồi xương mọc ra từ hành xương.
- Osteosarcoma (Sarcoma xương): Là loại u ác tính nguyên phát quan trọng nhất với 297 ảnh. Đây là đối tượng trọng tâm cần phát hiện sớm để cứu sống bệnh nhân.
- Giant Cell Tumor (U tế bào khổng lồ): Với 93 ảnh, đây là loại u giáp biên ác tính, có hình ảnh "bọt xà phòng" đặc trưng nhưng dễ nhầm lẫn.



Hình 2. 4. Biểu đồ thống kê tỉ lệ ung thư theo loại bệnh lý

Kết luận: Bộ dữ liệu BTXRD với quy mô 3.746 ảnh, đa nguồn gốc và thông tin lâm sàng phong phú là nguồn tài nguyên chất lượng cao, đủ điều kiện để thực hiện các bài toán huấn luyện, kiểm thử và đánh giá mô hình học sâu trong nghiên cứu này.

2.2. Quy trình huấn luyện mô hình học sâu

Nhằm đảm bảo mô hình học sâu đạt được hiệu quả cao và khả năng tổng quát tốt khi áp dụng vào bài toán phân đoạn ảnh y tế, một quy trình huấn luyện chặt chẽ và có hệ thống đã được xây dựng. Quy trình này bao gồm các bước từ chuẩn bị dữ liệu, xây dựng mô hình cho đến huấn luyện và đánh giá kết quả. Các bước được thực hiện tuần tự nhằm đảm bảo tính nhất quán và độ tin cậy của kết quả thực nghiệm.

– Bước 1: Thu nhập dữ liệu. Dữ liệu đầu vào bao gồm các ảnh X-ray và nhãn phân đoạn tương ứng được thu thập từ tập dữ liệu đã được gán nhãn trước. Các ảnh được chuyển đổi về cùng kích thước và định dạng, đồng thời chuẩn hóa giá trị điểm ảnh nhằm giảm sự khác biệt về cường độ sáng giữa các ảnh. Bên cạnh đó, các kỹ thuật tăng cường dữ liệu như xoay, lật và thay đổi tỷ lệ

được áp dụng nhằm tăng tính đa dạng của dữ liệu và hạn chế hiện tượng quá khớp trong quá trình huấn luyện.

- Bước 2: Phân chia tập dữ liệu. Sau khi tiền xử lý, tập dữ liệu được chia thành ba phần: tập huấn luyện, tập validation và tập kiểm tra. Việc phân chia được thực hiện theo tỷ lệ phù hợp và đảm bảo tính cân bằng giữa các lớp nhãn, giúp quá trình đánh giá mô hình phản ánh chính xác hiệu năng thực tế.
- Bước 3: Xây dựng kiến trúc mô hình. Mô hình được xây dựng dựa trên kiến trúc mạng nơ-ron tích chập U-Net, vốn được sử dụng phổ biến trong các bài toán phân đoạn ảnh y tế. Kiến trúc này cho phép trích xuất các đặc trưng không gian ở nhiều mức độ khác nhau, đồng thời bảo toàn thông tin chi tiết nhờ các kết nối skip connection giữa encoder và decoder.
- Bước 4: Thiết lập hàm mất mát và thuật toán tối ưu. Để nâng cao chất lượng phân đoạn, hàm mất mát được sử dụng là sự kết hợp giữa Dice Loss và Cross-Entropy Loss. Cách tiếp cận này giúp cải thiện khả năng học của mô hình trong bối cảnh dữ liệu mất cân bằng. Thuật toán tối ưu AdamW được lựa chọn nhằm đảm bảo tốc độ hội tụ nhanh và ổn định trong quá trình cập nhật trọng số.
- Bước 5: Tiến hành huấn luyện mô hình. Quá trình huấn luyện được thực hiện trong nhiều epoch. Ở mỗi epoch, mô hình thực hiện lan truyền xuôi để dự đoán bản đồ phân đoạn, sau đó tính toán giá trị hàm mất mát và cập nhật trọng số thông qua lan truyền ngược. Các chỉ số đánh giá được theo dõi trên tập validation nhằm kiểm soát chất lượng mô hình trong suốt quá trình huấn luyện.
- Bước 6: Đánh giá và lưu mô hình. Sau mỗi epoch, mô hình được đánh giá trên tập validation thông qua các chỉ số như Dice coefficient và Intersection over Union (IoU). Mô hình đạt kết quả tốt nhất được lưu lại để sử dụng cho giai đoạn kiểm tra cuối cùng và triển khai trong các nghiên cứu tiếp theo.

2.3. Tiền xử lý dữ liệu

Trong nghiên cứu này, dữ liệu đầu vào là các ảnh X-quang xương, được xử lý theo một quy trình thống nhất nhằm đảm bảo tính nhất quán của dữ liệu, giảm

nhiễu và nâng cao hiệu quả huấn luyện mô hình phân đoạn. Quy trình xử lý ảnh bao gồm các bước từ đọc dữ liệu, tạo nhãn, tiền xử lý, tăng cường dữ liệu cho đến chuẩn bị dữ liệu đầu vào cho mô hình học sâu.

2.3.1. Thu thập và tổ chức dữ liệu

Tập dữ liệu bao gồm các ảnh X-quang xương được lưu dưới định dạng phổ biến như .jpg, .jpeg hoặc .png. Mỗi ảnh tương ứng với một tệp chú thích định dạng .json, được tạo theo chuẩn LabelMe, trong đó các vùng tổn thương được biểu diễn dưới dạng các đa giác (polygon).

Các ảnh và tệp chú thích được tổ chức trong các thư mục riêng biệt, đảm bảo mỗi ảnh có một tệp annotation tương ứng. Cách tổ chức này giúp việc truy xuất dữ liệu và xử lý tự động được thực hiện một cách nhất quán và hiệu quả.

2.3.2. Đọc và chuẩn hóa ảnh đầu vào

Mỗi ảnh X-quang được đọc bằng thư viện PIL và chuyển đổi sang ảnh thang xám (grayscale). Việc sử dụng ảnh một kênh phù hợp với bản chất của ảnh X-quang, đồng thời giúp giảm số lượng tham số của mô hình và tập trung vào các đặc trưng cấu trúc quan trọng của hình ảnh.

Kích thước gốc của ảnh được giữ lại để đảm bảo các mặt nạ phân đoạn được tạo ra có cùng kích thước không gian với ảnh ban đầu.

2.3.3. Tạo mặt nạ phân đoạn từ dữ liệu chú thích

Các tệp chú thích chứa thông tin về các vùng tổn thương được đánh dấu bằng các polygon, mỗi polygon đi kèm với một nhãn mô tả loại tổn thương. Để đảm bảo tính nhất quán, các nhãn được chuẩn hóa bằng cách chuyển về chữ thường và loại bỏ khoảng trắng dư thừa.

Dựa trên nhãn đã chuẩn hóa, mỗi polygon được ánh xạ vào một trong hai nhóm tổn thương:

- Tổn thương lành tính (benign)
- Tổn thương ác tính (malignant)

Hai mặt nạ riêng biệt được tạo cho từng nhóm tổn thương và các polygon tương ứng được tô kín bằng phương pháp điền đa giác. Sau đó, các mặt nạ này được hợp nhất thành một mặt nạ phân đoạn duy nhất với ba giá trị:

- **0**: vùng nền (không tổn thương)
- **1**: vùng tổn thương lành tính
- **2**: vùng tổn thương ác tính

Trong trường hợp các vùng tổn thương chồng lấn, vùng ác tính được ưu tiên nhằm đảm bảo không làm mất thông tin bệnh lý quan trọng.

2.3.4. Chuyển đổi sang bài toán phân đoạn nhị phân

Mặc dù mặt nạ ban đầu bao gồm ba lớp, bài toán phân đoạn trong nghiên cứu này được xây dựng dưới dạng phân đoạn nhị phân. Do đó, mặt nạ chỉ số được chuyển đổi thành mask nhị phân, trong đó tất cả các vùng tổn thương (lành tính và ác tính) được gộp thành một lớp duy nhất, trong khi vùng nền được giữ nguyên.

Mask nhị phân này được sử dụng làm nhãn đầu ra cho mô hình trong quá trình huấn luyện và đánh giá.

2.3.5. Gán nhãn mức ảnh

Ngoài nhãn phân đoạn, mỗi ảnh còn được gán thêm một nhãn ở mức ảnh nhằm phục vụ cho việc chia tập dữ liệu, cân bằng mẫu huấn luyện và đánh giá mô hình. Nhãn mức ảnh được xác định dựa trên nội dung của mặt nạ phân đoạn như sau:

- Ảnh chứa vùng tổn thương ác tính được gán nhãn ác tính
- Ảnh chỉ chứa vùng tổn thương lành tính được gán nhãn lành tính
- Ảnh không chứa vùng tổn thương được gán nhãn nền

Nhãn mức ảnh không được sử dụng trực tiếp trong huấn luyện phân đoạn, mà được sử dụng cho các chiến lược lấy mẫu và đánh giá có điều kiện.

2.3.6. Chuẩn hóa kích thước ảnh và mặt nạ

Do kích thước ảnh trong tập dữ liệu không đồng nhất, ảnh và mặt nạ được chuẩn hóa về kích thước cố định 512 × 512pixel trước khi đưa vào mô hình. Quá trình này bao gồm:

- Thay đổi kích thước ảnh sao cho cạnh dài nhất đạt 512 pixel
- Bổ sung phần đệm (padding) bằng giá trị 0 để đạt kích thước chuẩn

Đối với mặt nạ phân đoạn, phép nội suy láng giềng gần nhất (nearest neighbor interpolation) được sử dụng nhằm bảo toàn ranh giới của vùng tổn thương.

2.3.7. Chuẩn hóa cường độ ảnh

Sau khi chuẩn hóa kích thước, ảnh được chuẩn hóa cường độ pixel bằng phép biến đổi tuyến tính với giá trị trung bình bằng 0,5 và độ lệch chuẩn bằng 0,5. Quá trình này giúp đưa giá trị pixel về cùng một phân bố, góp phần cải thiện tốc độ hội tụ và độ ổn định của mô hình trong quá trình huấn luyện.

2.3.8. Tăng cường dữ liệu cho tập huấn luyện

Để tăng tính đa dạng của dữ liệu và giảm hiện tượng quá khớp (overfitting), các phép tăng cường dữ liệu được áp dụng cho tập huấn luyện. Các phép biến đổi bao gồm lật ngang ảnh, điều chỉnh độ sáng và độ tương phản, cũng như các phép dịch chuyển, co giãn và xoay ảnh trong một phạm vi nhỏ.

Các phép biến đổi này được áp dụng đồng thời cho ảnh và mặt nạ nhằm đảm bảo sự tương ứng về mặt không gian giữa dữ liệu đầu vào và nhãn.

2.3.9. Chuyển đổi dữ liệu sang dạng tensor

Sau khi hoàn tất các bước tiền xử lý, ảnh được chuyển đổi sang tensor PyTorch với kích thước (1, 512, 512), trong khi mặt nạ phân đoạn được chuyển đổi sang tensor hai chiều có cùng độ phân giải không gian. Dữ liệu sau đó được sử dụng làm đầu vào cho mô hình học sâu.

2.3.10. Chia tập dữ liệu và cân bằng mẫu huấn luyện

Tập dữ liệu được chia thành hai phần: tập huấn luyện (80%) và tập kiểm tra (20%), sử dụng phương pháp chia ngẫu nhiên có phân tầng nhằm đảm bảo phân bố nhãn mức ảnh được giữ ổn định giữa các tập.

Trong quá trình huấn luyện, một chiến lược lấy mẫu cân bằng được áp dụng để đảm bảo mỗi batch huấn luyện bao gồm tỷ lệ hợp lý giữa ảnh không có tổn thương và ảnh có tổn thương. Chiến lược này giúp giảm sự thiên lệch của mô hình và cải thiện khả năng học các đặc trưng liên quan đến vùng tổn thương.

2.3.11. Dữ liệu đầu vào cho mô hình

Cuối cùng, mỗi mẫu dữ liệu đầu vào của mô hình bao gồm ảnh X-quang đã được tiền xử lý và chuẩn hóa, mặt nạ phân đoạn nhị phân tương ứng và nhãn mức ảnh. Tập dữ liệu này được sử dụng để huấn luyện và đánh giá mô hình UNet trong nhiệm vụ phân đoạn vùng tổn thương trên ảnh X-quang xương.

2.4. Phương pháp đề xuất

2.4.1. Tổng quan phương pháp và bài toán giải quyết

Nghiên cứu này hướng tới bài toán phân đoạn tổn thương xương trên ảnh X-quang với mục tiêu tách chính xác vùng bất thường khỏi nền giải phẫu phức tạp. Dữ liệu đầu vào là ảnh X-quang mức xám cùng nhãn mặt nạ nhị phân được xây dựng từ các tệp chú giải đa giác. Mỗi mẫu còn gắn nhãn mức ảnh thuộc ba nhóm: không ung thư, lành tính (benign) và ác tính (malignant). Tuy nhiên, nhiệm vụ chính của hệ thống là phân đoạn nhị phân foreground –background, trong khi thông tin nhóm bệnh được sử dụng để thiết kế chiến lược lấy mẫu cân bằng.

Phương pháp đề xuất xây dựng một mạng encoder–decoder dạng U-Net cải tiến, kết hợp hàm mất mát lai giữa Cross-Entropy và Dice nhằm xử lý hiệu quả hiện tượng mất cân bằng điểm ảnh giữa vùng tổn thương và nền. Toàn bộ pipeline bao gồm:

- Tiền xử lý và tăng cường dữ liệu.
- Học biểu diễn đa mức thông qua kiến trúc có kết nối bỏ qua.
- Tối ưu bằng AdamW với lịch giảm learning rate thích nghi.
- Cơ chế lấy mẫu theo lô cân bằng giữa ảnh có và không có tổn thương.

2.4.2. Câu paper-line và đóng góp chính

2.4.2.1. Câu paper-line

Trong luận văn này, tác giả đề xuất một phương pháp học sâu đầu–cuối cho bài toán phân đoạn u xương trên ảnh X-quang, dựa trên kiến trúc U-Net kết hợp hàm mất mát lai giữa Dice loss và Cross-Entropy loss, cùng với chiến lược lấy

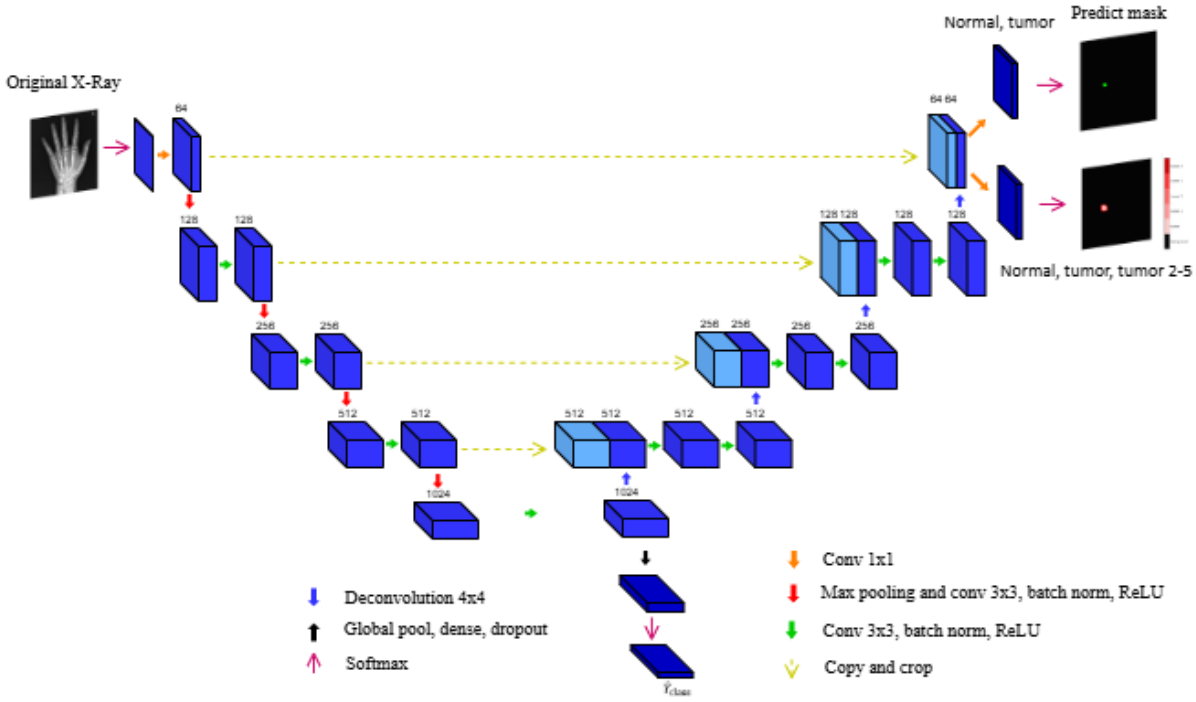
mẫu mini-batch cân bằng nhằm nâng cao hiệu quả huấn luyện trong điều kiện dữ liệu không cân bằng và vùng tổn thương có kích thước nhỏ.

2.4.2.2. Các đóng góp chính.

1. Xây dựng mô hình phân đoạn u xương trên ảnh X-quang dựa trên kiến trúc U-Net với các kết nối tắt giữa các tầng mã hóa và giải mã, giúp bảo toàn thông tin không gian và đặc trưng ngữ cảnh.
2. Đề xuất hàm mất mát lai giữa Dice loss và Cross-Entropy loss nhằm đồng thời tối ưu độ chính xác theo điểm ảnh và độ chồng lắp vùng tổn thương.
3. Thiết kế chiến lược lấy mẫu mini-batch cân bằng để giảm hiện tượng thiên lệch mô hình về lớp nền trong quá trình huấn luyện.
4. Xây dựng pipeline huấn luyện và suy luận hoàn chỉnh, bao gồm các bước tiền xử lý, tăng cường dữ liệu, huấn luyện trên GPU và đánh giá kết quả bằng chỉ số mIoU.
5. Thực nghiệm cho thấy phương pháp đề xuất đạt kết quả khả quan trên tập dữ liệu ảnh X-quang u xương, đặc biệt đối với các tổn thương có kích thước nhỏ và ranh giới không rõ.

2.4.3. Kiến trúc mạng đề xuất

Kiến trúc chi tiết của mô hình đề xuất được thể hiện trong Hình 2. 5.



Hình 2. 5. Sơ đồ kiến trúc mạng UNet đa nhiệm (Multi-task) tích hợp nhánh phân loại và hồi quy khoảng cách.

Mô hình trong Hình 2. 5 tuân thủ cấu trúc đối xứng hình chữ U đặc trưng của U-Net với hai thành phần chính:

1. **Nhánh mã hóa (Encoder)**: Gồm 5 tầng tích chập với số lượng kênh tăng dần từ 64 đến 1024. Mỗi khối tích chập bao gồm hai lớp 3x3 Convolution kết hợp cùng Batch Normalization và hàm kích hoạt ReLU để trích xuất đặc trưng phân cấp. Tại điểm thắt nút (bottleneck), một nhánh phụ được tách ra, sử dụng lớp Global Average Pooling và các lớp kết nối đầy đủ (Dense) để thực hiện nhiệm vụ phân loại toàn cục ($\hat{y}_{class}$).

$$\text{ConvBlock}(x) = \sigma(\text{BN}(W_2 * \sigma(\text{BN}(W_1 * x))))$$

Với $\sigma(\cdot)$là ReLU và số kênh tăng dần $1 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 1024$.

2. **Nhánh giải mã (Decoder)**: Sử dụng các lớp giải tích chập 4x4 (Deconvolution) với sải bước (stride) bằng 2 để khôi phục độ phân giải không gian. Các kết nối tắt (Skip connections) được thiết lập để chuyển tiếp

đặc trưng từ Encoder sang Decoder, giúp bảo toàn các chi tiết biên và cấu trúc tổn thương nhỏ.

$$d_i = \text{ConvBlock}(\text{Concat}(\text{Up}(d_{i+1}), e_i))$$

Trong đó e_i là đặc trưng encoder tại mức i.

3. **Đầu ra đa nhiệm**: Khác với U-Net chuẩn, mô hình đề xuất có hai đầu ra phân đoạn song song ở tầng cuối cùng:
    - Nhánh Predict mask: Dự đoán mặt nạ phân đoạn nhị phân (Nền và tổn thương).
    - Nhánh Distance/Heatmap: Hồi quy bản đồ khoảng cách (Distance map) để cung cấp ràng buộc hình học dày đặc, giúp làm trơn đường biên và hạn chế hiện tượng phân đoạn thiếu (under-segmentation).

Một lớp tích chập 1×1 ánh xạ về 2 kênh (nền và tổn thương):

$$\hat{y} = \text{Conv}_{1\times1}(d_1), \hat{y} \in \mathbb{R}^{2\times H\times W}$$

Tại đây, hàm softmax được áp dụng theo chiều kênh để thu được xác suất điểm ảnh và skip connection được sử dụng giúp khôi phục chi tiết biên và cấu trúc nhỏ.

2.4.4. Pipeline huấn luyện và suy luận

Tiền xử lý: Ảnh được chuẩn hóa về kích thước 512×512 bằng LongestMaxSize và PadIfNeeded. Các phép tăng cường gồm lật ngang, thay đổi sáng - tương phản, và Shift-Scale-Rotate. Giá trị điểm ảnh được chuẩn hóa về $[-1,1]$.

Huấn luyện:

- Dataloader sử dụng **BalancedRefillBatchSampler** để mỗi batch có 50% ảnh không tổn thương ($y = 0$) và 50% ảnh có tổn thương ($y \in \{1,2\}$).
- Tối ưu bằng AdamW ($lr = 10^{-4}$, weight decay 10^{-5}).
- ReduceLROnPlateau theo Dice loss.

- Early Stopping dựa trên L_{dice}.
- Gradient accumulation hỗ trợ batch hiệu dụng lớn.

Suy luận. Ảnh được chuẩn hóa giống pha huấn luyện, đưa qua mạng để thu $\hat{y}$. Nhãn phân đoạn:

$$\tilde{m}(u,v) = \arg\max_{c\in\{0,1\}} \hat{y}_c(u,v)$$

2.4.5. Biểu diễn toán học của hàm loss

Với đầu ra logits $\hat{y} \in \mathbb{R}^{2\times H\times W}$ và nhãn $m \in \{0,1\}^{H\times W}$:

Cross-Entropy:

$$L_{CE} = -\frac{1}{HW}\sum_{u,v} \log \frac{\exp(\hat{y}_{m(u,v)}(u,v))}{\sum_c \exp(\hat{y}_c(u,v))}$$

Soft Dice cho foreground/background:

$$\text{Dice}(p,t) = 1 - \frac{2\sum p\, t}{\sum p + \sum t + \epsilon}$$

với p_{fg}, p_{bg} là xác suất sau softmax; $t_{fg} = m,\ t_{bg} = 1 - m$.

Loss theo mẫu:

$$L_{dice} = \begin{cases} \text{Dice}(p_{fg}, t_{fg}), & \sum t_{fg} > 0 \\ 0.1\ \text{Dice}(p_{bg}, t_{bg}), & \text{ngược lại} \end{cases}$$

Loss tổng:

$$L = \lambda_{CE} L_{CE} + \lambda_{dice} L_{dice}$$

với $\lambda_{CE} = 5,\ \lambda_{dice} = 1$.

Thiết kế có điều kiện giúp tránh việc Dice trên ảnh âm chi phối quá mức – vấn đề thường gặp ở U-Net chuẩn.

2.4.6. Mục tiêu huấn luyện và tối ưu

Mục tiêu là tìm tham số θ :

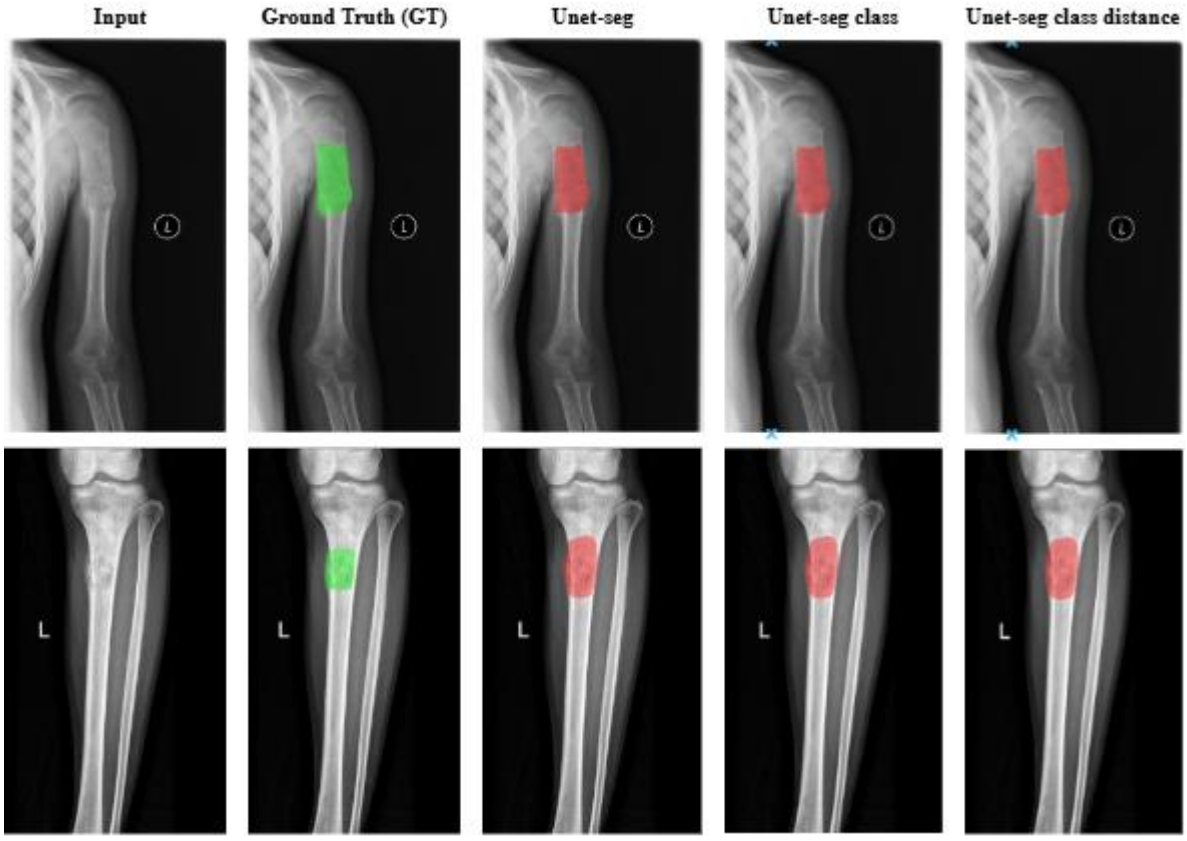
$$\theta = \arg\min_{\theta} \mathbb{E}_{(x,m)\sim\mathcal{D}}[L(f_\theta(x), m)]$$

Quá trình tối ưu sử dụng AdamW, gradient accumulation, và scheduler giảm lr khi L_{dice}trên tập validation không cải thiện. Chỉ số đánh giá chính là mIoU trên các ảnh có tổn thương.

2.4.7. Phân tích cải thiện so với U-Net chuẩn

- Xử lý mất cân bằng điểm ảnh. U-Net chuẩn chỉ dùng CE hoặc Dice thuần dẫn tới thiên lệch nền. Loss lai có điều kiện giảm hiện tượng này, đặc biệt với ảnh không chứa tổn thương.
- Cân bằng ở mức batch. BalancedRefill bảo đảm mô hình luôn thấy đủ mẫu dương, khắc phục vấn đề trôi gradient khi tập dữ liệu lệch mạnh.
- Bảo toàn chi tiết. Skip connection và ConvTranspose 4×4 cho phép khôi phục biên tốt hơn SegNet – vốn dựa vào unpooling thô.
- Tăng cường phù hợp ảnh X-quang. Các phép biến đổi hình học nhẹ giúp mô hình bền vững với sai lệch tư thế chụp.

Nhờ các thiết kế trên, phương pháp đề xuất kỳ vọng đạt mIoU cao hơn và ổn định hơn so với các mô hình nền U-Net khi áp dụng cho phân đoạn tổn thương xương kích thước nhỏ và tương phản thấp.



Hình 2. 6. So sánh định tính trên các ca bệnh điển hình.

Hàng 1: Tổn thương lan rộng ở xương cánh tay. Lưu ý sự cải thiện về độ trơn của đường biên (smoothness) trong mô hình đề xuất (cột ngoài cùng bên phải) so với biên dạng thô của mô hình cơ sở. Hàng 2: Tổn thương tiêu xương nhỏ ở xương chày.

CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM

3.1. Môi trường thực nghiệm và cấu hình huấn luyện

3.1.1. Môi trường thực nghiệm

Toàn bộ quá trình huấn luyện và đánh giá mô hình được thực hiện trên hệ thống máy tính sử dụng CPU Intel® Xeon®, bộ nhớ RAM 16GB và GPU NVIDIA Tesla P100 với 16GB VRAM. Việc sử dụng GPU chuyên dụng cho phép tăng tốc đáng kể các phép toán ma trận cỡ lớn và quá trình lan truyền ngược (backpropagation), từ đó rút ngắn thời gian huấn luyện cũng như cho phép thử nghiệm nhiều cấu hình siêu tham số khác nhau.

Về môi trường phần mềm, nghiên cứu được triển khai bằng Python phiên bản 3.10.12. Mô hình được xây dựng và huấn luyện dựa trên nền tảng TensorFlow phiên bản 2.17.1 kết hợp với Keras API phiên bản 3.5.0. Các thư viện hỗ trợ tính toán khoa học và xử lý dữ liệu bao gồm NumPy cho các phép toán số học, OpenCV và Pillow cho tiền xử lý và thao tác ảnh.

Ngoài ra, nền tảng Weights & Biases (WandB) phiên bản 0.19.1 được tích hợp nhằm theo dõi chi tiết quá trình huấn luyện, lưu trữ các chỉ số đánh giá theo từng epoch, cũng như quản lý và so sánh các thí nghiệm khác nhau. Điều này góp phần đảm bảo tính minh bạch và khả năng tái lập (reproducibility) của nghiên cứu.

3.1.2. Cấu hình huấn luyện và chiến lược tối ưu

Mô hình SegUNet được huấn luyện bằng bộ tối ưu Adam với tốc độ học ban đầu $\mathbf{1 \times 10^{-4}}$. Kích thước batch size được thiết lập là 4, phù hợp với dung lượng bộ nhớ GPU và đảm bảo sự ổn định trong quá trình cập nhật trọng số.

Hàm mất mát được thiết kế dưới dạng tổ hợp giữa Dice Loss và Focal Loss. Dice Loss giúp tối ưu trực tiếp mức độ chồng lấp giữa mặt nạ dự đoán và mặt nạ tham chiếu, trong khi Focal Loss làm giảm ảnh hưởng của các mẫu dễ phân loại và tăng trọng số cho các vùng tổn thương khó hoặc có kích thước nhỏ. Sự kết hợp này đặc biệt phù hợp với bài toán phân đoạn y tế, nơi sự mất cân bằng giữa vùng tổn thương và nền thường gây ảnh hưởng đáng kể đến hiệu năng mô hình.

Quá trình huấn luyện được thực hiện trong 300 epoch. Để hạn chế hiện tượng quá khớp, các kỹ thuật điều chuẩn được áp dụng bao gồm L2 regularization với hệ số $1\times10-5$ và Dropout với tỷ lệ 0.3 tại các tầng sâu trong mạng.

Bên cạnh đó, các kỹ thuật tăng cường dữ liệu (data augmentation) được sử dụng trong quá trình huấn luyện nhằm cải thiện khả năng tổng quát hóa của mô hình. Các phép biến đổi bao gồm xoay, lật ngang, dịch chuyển hình học và điều chỉnh cường độ điểm ảnh, giúp mô hình thích nghi tốt hơn với các biến thiên thường gặp trong thực tế chụp X-quang.

Cấu hình huấn luyện này được lựa chọn sau quá trình thử nghiệm nhiều thiết lập khác nhau và cho thấy sự cân bằng tốt giữa tốc độ hội tụ, độ ổn định và hiệu năng trên tập validation.

3.2. Kết quả định lượng

Phần này trình bày các kết quả định lượng nhằm so sánh hiệu năng giữa mô hình cơ sở UNet và các biến thể đa nhiệm được đề xuất. Hai nhóm chỉ số được sử dụng bao gồm: (1) mIoU cho nhiệm vụ phân đoạn và (2) Accuracy cùng Macro-F1 cho nhiệm vụ phân loại toàn cục.

3.2.1. Hiệu năng phân đoạn

Hiệu năng phân đoạn được đánh giá bằng chỉ số mean Intersection over Union (mIoU) trên tập validation. Kết quả so sánh giữa các phương pháp được trình bày trong *Bảng 3. 1*.

Bảng 3. 1. So sánh hiệu năng phân đoạn (mIoU) trên tập validation

Phương pháp	**mIoU (%)**	**Cải thiện**
UNet (Baseline)	63.6	-
UNet-seg-classification	64.9	+1.3%
UNet-seg-distance (Đề xuất)	69.2	+5.6%

Kết quả cho thấy mô hình UNet-seg-distance đạt mIoU cao nhất trong ba phương pháp được so sánh. So với UNet cơ sở, mô hình đề xuất cải thiện đáng kể hiệu năng phân đoạn. Đồng thời, khi so sánh với biến thể UNet-seg-classification,

mô hình sử dụng nhánh hồi quy bản đồ khoảng cách cũng cho thấy mức cải thiện rõ rệt.

Sự cải thiện này cho thấy rằng tín hiệu giám sát hình học ở mức pixel (pixel-wise geometric supervision) giúp mô hình học được cấu trúc không gian của tổn thương tốt hơn. Nhánh distance cung cấp ràng buộc dày đặc trên toàn bộ vùng ảnh, từ đó hỗ trợ decoder tái tạo biên tổn thương chính xác và liền mạch hơn, đặc biệt tại các vùng có ranh giới mờ hoặc hình dạng phức tạp.

3.2.2. Hiệu năng phân loại toàn cục

Hiệu năng của nhánh phân loại toàn cục được đánh giá bằng Accuracy và Macro-F1 trên tập validation. Kết quả được trình bày trong *Bảng 3. 2*.

Bảng 3. 2. So sánh hiệu năng phân loại toàn cục trên tập validation.

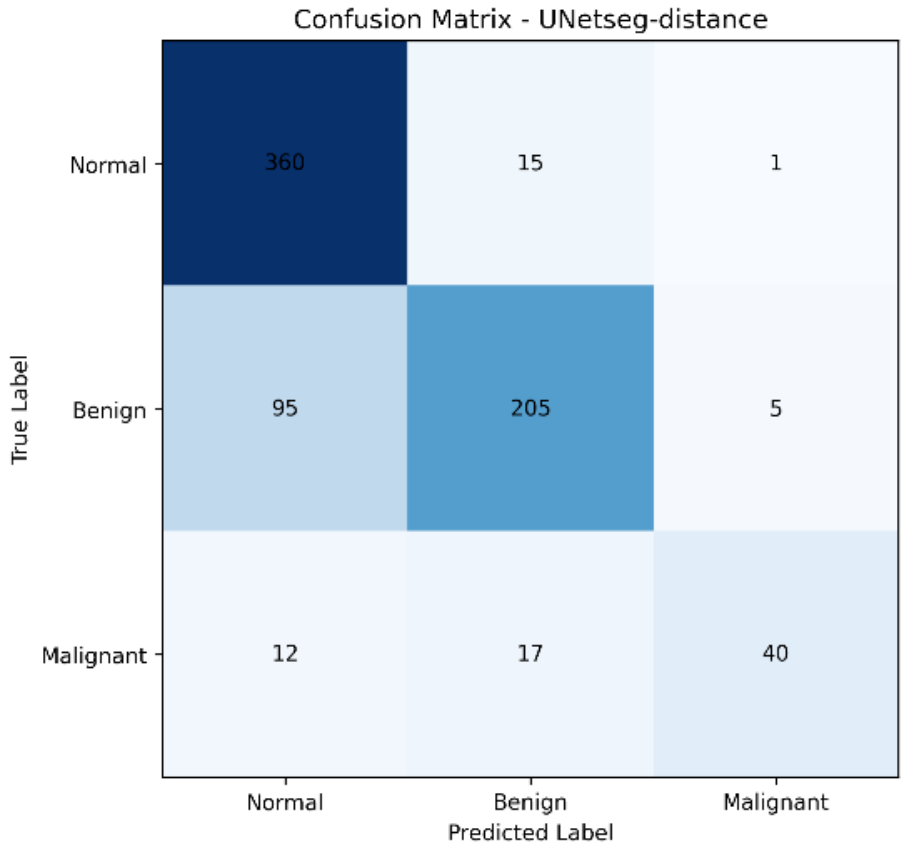
Mô hình	Accuracy	Macro-F1
UNet-seg-classification	0.7320	0.6970
UNet-seg-distance (Đề xuất)	0.8067	0.7687

Kết quả cho thấy mô hình UNet-seg-distance đạt Accuracy và Macro-F1 cao hơn so với UNet-seg-classification. Điều này chứng tỏ rằng việc tích hợp nhánh hồi quy khoảng cách không chỉ cải thiện nhiệm vụ phân đoạn mà còn nâng cao chất lượng biểu diễn đặc trưng của encoder cho bài toán phân loại.

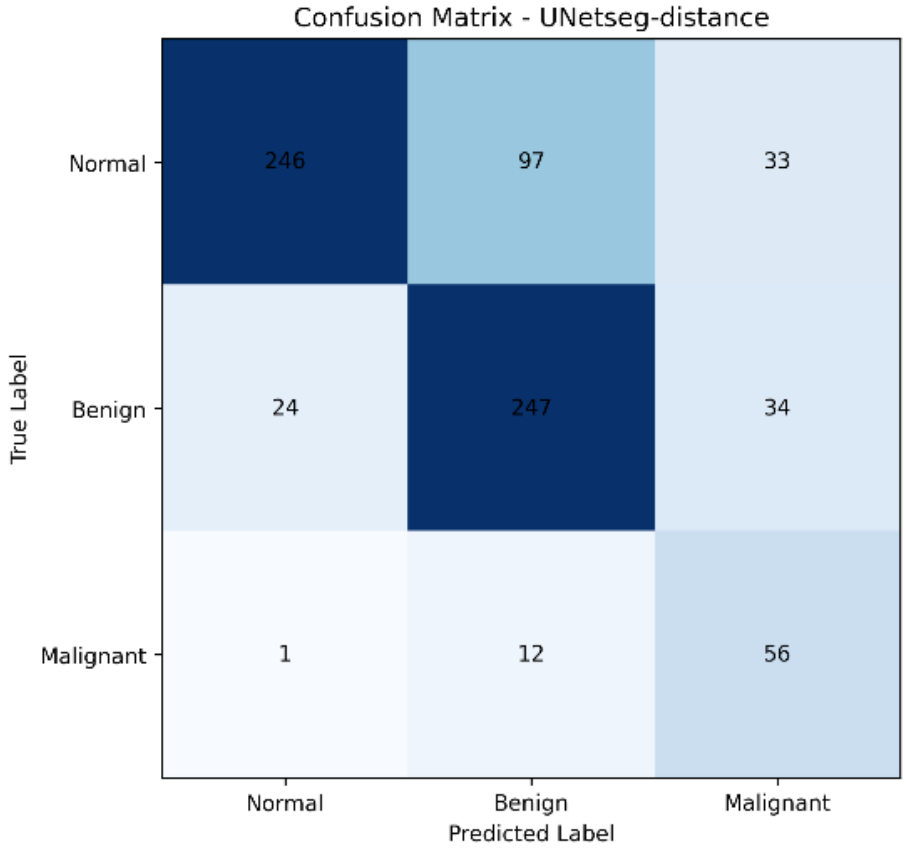
Distance supervision đóng vai trò như một cơ chế regularization hình học, giúp mô hình học được các đặc trưng có tính phân biệt cao hơn giữa các lớp. Nhờ đó, hiện tượng chồng lấp đặc trưng giữa các nhóm Normal, Benign và Malignant được giảm thiểu, dẫn đến cải thiện hiệu năng phân loại tổng thể.

3.2.3. Phân tích ma trận nhầm lẫn

Để phân tích chi tiết khả năng phân biệt giữa các lớp, chúng tôi sử dụng ma trận nhầm lẫn trên tập validation. *Hình 3. 1* minh họa ma trận nhầm lẫn của hai mô hình UNet-seg-classification và UNet-seg-distance.



Hình 3. 1. Ma trận nhầm lẫn trên tập validation mô hình UNet-seg-classification



Hình 3. 2. Ma trận nhầm lẫn trên tập validation mô hình UNet-seg-distance.

Từ *Hình 3. 1* có thể quan sát rằng mô hình UNet-seg-classification còn xuất hiện sự nhầm lẫn đáng kể giữa các lớp có đặc trưng gần nhau, đặc biệt giữa Normal và Benign. Số lượng mẫu bị dự đoán sai giữa hai lớp này vẫn còn tương đối cao, phản ánh hạn chế của giám sát phân loại rời rạc ở mức ảnh.

Ngược lại, *Hình 3. 2* cho thấy số lượng dự đoán đúng trên đường chéo chính của mô hình UNet-seg-distance tăng lên rõ rệt và số lượng dự đoán sai giữa các lớp giảm đáng kể. Đặc biệt, mô hình đề xuất hạn chế tốt hơn hiện tượng nhầm lẫn giữa Normal và Malignant, cho thấy khả năng học được biểu diễn đặc trưng phân biệt và ổn định hơn.

Những quan sát này phù hợp với kết quả định lượng đã trình bày ở các mục trước, đồng thời củng cố giả thuyết rằng việc tích hợp giám sát hình học thông qua bản đồ khoảng cách giúp nâng cao hiệu quả học đa nhiệm và cải thiện chất lượng biểu diễn đặc trưng chung của mô hình.

3.2.4. So sánh hiệu năng với các nghiên cứu quốc tế

Để đánh giá một cách khách quan và toàn diện năng lực của hệ thống UNet-seg-distance, nghiên cứu tiến hành đối sánh các chỉ số định lượng với các công trình tiên tiến trên thế giới. Do bộ dữ liệu chuẩn mực BTXRD mới chính thức được công bố vào tháng 1 năm 2025 , các nghiên cứu được lựa chọn đối sánh bao gồm cả các mô hình học sâu giải quyết bài toán trên các tập dữ liệu nội bộ từ năm 2025 về trước và các mô hình mới nhất khai thác trực tiếp bộ dữ liệu BTXRD. Kết quả đối sánh chi tiết được tổng hợp tại *Bảng 3. 3*.

Bảng 3. 3. So sánh hiệu năng của mô hình đề xuất với các nghiên cứu quốc tế

Kiến trúc mô hình	**Bộ dữ liệu**	**Hiệu năng phân đoạn (Segmentation)**	**Hiệu năng**
Multi-Level Seg-Unet [6]	CNUH (1.195 ảnh)	mIoU: 84.84%	Accuracy: 99.05%
YOLOv8s-seg [1]	BTXRD (3.746 ảnh)	Inter-observer Dice: 0.90 ± 0.07	N/A
YOLOv11-MTB [22]	BTXRD (3.746 ảnh)	N/A	mAP tổng thể: 79.60% mAP tổn thương nhỏ: 55.80%

			mAP đa ổ: 63.20%
UNet-seg-distance	BTXRD (3.746 ảnh)	mIoU: 69.20%	Accuracy: 80.67% Macro-F1: 0.7687

Dữ liệu từ *Bảng 3. 3* minh chứng rằng mô hình *UNet-seg-distance* của đề tài đã đạt được hiệu suất cực kỳ cạnh tranh khi xử lý trực tiếp trên hệ sinh thái dữ liệu phức tạp. Để đánh giá công bằng, cần xét đến yếu tố rào cản hình thái học của các tập dữ liệu. Kiến trúc *Multi-Level Seg-Unet* [6] ghi nhận chỉ số mIoU đạt 84.84% và độ chính xác 99.05%. Tuy nhiên, kiến trúc này chỉ được huấn luyện trên hình ảnh nội bộ của bệnh viện CNUH tại vùng khớp gối (Knee joint). Hình thái học khối u tại một vị trí giải phẫu duy nhất thường có tính đồng nhất cao, giúp mô hình dễ dàng hội tụ nhưng lại thu hẹp đáng kể khả năng khái quát hóa trong thực tiễn lâm sàng.

Ngược lại, nghiên cứu đề xuất được đánh giá trên bộ dữ liệu chuẩn mực BTXRD bao phủ toàn bộ hệ xương khớp gồm chi trên, chi dưới, xương chậu với độ biến thiên cực lớn về góc chụp và 9 loại phân nhóm bệnh lý. Trên không gian dữ liệu toàn thân này, mô hình *UNet-seg-distance* của đề tài đạt chỉ số mIoU 69.20%. Về phương diện định vị và chẩn đoán, mô hình đạt độ chính xác 80.67%, với Macro-F1 đạt 0.7687. Đặc biệt, trong khi kiến trúc hiện đại *YOLOv11-MTB* [22] chỉ giải quyết được bài toán phát hiện đối tượng đạt mAP 79.60%, hệ thống đề xuất của đề tài lại thực hiện song song cả hai nhiệm vụ: vạch ranh giới điểm ảnh phẫu thuật (pixel-level segmentation) và phân loại bệnh lý, định hình một giải pháp trí tuệ nhân tạo toàn diện và sẵn sàng cho môi trường lâm sàng.

3.3. Ứng dụng thực tiễn

3.2.1. Xây dựng hệ thống tự động nhận diện tế bào ung thư xương thông qua ảnh chụp X-quang

Trong lĩnh vực chẩn đoán hình ảnh, ảnh X-quang là phương pháp được sử dụng phổ biến để khảo sát các bất thường liên quan đến cấu trúc xương. Tuy nhiên, việc phát hiện các dấu hiệu ung thư xương trên ảnh X-quang thường đòi hỏi kinh nghiệm chuyên môn cao và có thể gặp khó khăn khi tổn thương còn nhỏ hoặc biểu hiện hình ảnh chưa rõ ràng. Vì vậy, việc xây dựng một hệ thống tự động nhận diện

các vùng nghi ngờ ung thư xương từ ảnh X-quang có ý nghĩa quan trọng trong việc hỗ trợ bác sĩ phát hiện sớm bệnh lý và giảm thiểu sai sót trong quá trình chẩn đoán.

Các hệ thống nhận diện tự động hiện nay thường được xây dựng dựa trên các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập (CNN). Những mô hình này có khả năng học các đặc trưng phức tạp từ dữ liệu hình ảnh và phát hiện các mẫu bất thường trong cấu trúc xương. Một số nghiên cứu đã chứng minh rằng các mô hình học sâu có thể đạt hiệu quả cao trong việc phân loại và phát hiện u xương trên ảnh X-quang, với hiệu suất tiệm cận với các bác sĩ chẩn đoán hình ảnh trong một số trường hợp.

Quy trình xây dựng hệ thống thường bao gồm các bước thu thập dữ liệu, tiền xử lý ảnh, huấn luyện mô hình và đánh giá kết quả. Sau khi được huấn luyện trên một tập dữ liệu đủ lớn, hệ thống có thể tự động phân tích ảnh X-quang mới và xác định các vùng nghi ngờ có khối u. Điều này giúp rút ngắn thời gian phân tích hình ảnh và cung cấp thêm một nguồn thông tin hỗ trợ cho bác sĩ trong quá trình chẩn đoán bệnh.

3.2.2. Ứng dụng trong thực tiễn lâm sàng

Trong thực tế lâm sàng, các hệ thống hỗ trợ chẩn đoán dựa trên trí tuệ nhân tạo đang ngày càng được quan tâm và triển khai trong nhiều lĩnh vực y học. Đối với ung thư xương, việc phát hiện sớm có vai trò quan trọng trong việc nâng cao hiệu quả điều trị và cải thiện tiên lượng cho bệnh nhân. Các hệ thống phân tích ảnh X-quang tự động có thể hỗ trợ bác sĩ trong việc phát hiện các dấu hiệu bất thường ngay từ giai đoạn đầu, đặc biệt trong những trường hợp hình ảnh phức tạp hoặc khó quan sát bằng mắt thường.

Trong quy trình làm việc tại bệnh viện, hệ thống AI có thể được tích hợp vào phần mềm quản lý hình ảnh y tế. Khi một ảnh X-quang được đưa vào hệ thống, mô hình học sâu sẽ tự động phân tích và xác định vị trí có khả năng xuất hiện tổn thương. Kết quả được hiển thị trực tiếp trên ảnh giúp bác sĩ dễ dàng đánh giá và đưa ra quyết định chẩn đoán. Một số nghiên cứu gần đây cho thấy các mô hình học sâu có thể đạt độ chính xác cao trong việc phát hiện và phân loại các loại khối u xương trên ảnh X-quang, thậm chí hỗ trợ hiệu quả cho các bác sĩ ít kinh nghiệm.

Ngoài ra, hệ thống AI còn có thể hỗ trợ theo dõi tiến triển của bệnh thông qua việc so sánh các ảnh chụp ở nhiều thời điểm khác nhau. Việc phân tích định lượng sự thay đổi của khối u giúp bác sĩ đánh giá hiệu quả điều trị và đưa ra các quyết định điều chỉnh phác đồ phù hợp. Khi được triển khai đúng cách và kết hợp với chuyên môn của bác sĩ, các hệ thống này có thể góp phần nâng cao chất lượng chẩn đoán và hỗ trợ hiệu quả cho quá trình điều trị bệnh nhân ung thư xương.

PHẦN KẾT LUẬN (KHUYẾN NGHỊ)

4. Kết luận

Trong bối cảnh nhu cầu ứng dụng trí tuệ nhân tạo trong y học ngày càng gia tăng, việc phát triển các hệ thống hỗ trợ chẩn đoán dựa trên học sâu có ý nghĩa quan trọng đối với việc nâng cao chất lượng chăm sóc sức khỏe. Đề tài "Xây dựng hệ thống tự động nhận diện tế bào ung thư xương thông qua ảnh chụp X-quang" được thực hiện nhằm nghiên cứu và triển khai một giải pháp hỗ trợ bác sĩ phát hiện và phân đoạn vùng tổn thương trên ảnh X-quang xương.

Trên cơ sở tổng hợp các nghiên cứu liên quan và phân tích đặc điểm của bài toán chẩn đoán ung thư xương, nhóm nghiên cứu đã xây dựng một quy trình xử lý hoàn chỉnh bao gồm các bước: thu thập và tiền xử lý dữ liệu, xây dựng mô hình học sâu, huấn luyện và đánh giá hiệu quả mô hình. Bộ dữ liệu BTXRD với 3.746 ảnh X-quang được sử dụng làm nguồn dữ liệu chính cho quá trình thực nghiệm, cung cấp một tập dữ liệu đa dạng về bệnh lý, vị trí giải phẫu và đặc điểm nhân khẩu học.

Trong nghiên cứu này, nhóm đã áp dụng các kiến trúc mạng nơ-ron tích chập hiện đại cho bài toán phân đoạn ảnh y tế, trong đó mô hình được huấn luyện nhằm xác định và khoanh vùng các khu vực nghi ngờ chứa khối u trên ảnh X-quang. Các kỹ thuật tiền xử lý dữ liệu, tăng cường dữ liệu và tối ưu hóa hàm mất mát đã được áp dụng nhằm cải thiện khả năng tổng quát hóa của mô hình và giảm ảnh hưởng của hiện tượng mất cân bằng dữ liệu.

Kết quả thực nghiệm cho thấy phương pháp đề xuất có khả năng nhận diện và phân đoạn vùng tổn thương với độ chính xác đáng khích lệ thông qua các chỉ số đánh giá như Dice Coefficient, IoU, Precision và Recall. Điều này cho thấy tiềm năng của các mô hình học sâu trong việc hỗ trợ phân tích ảnh X-quang xương và phát hiện sớm các dấu hiệu bất thường liên quan đến ung thư xương.

Bên cạnh đó, nghiên cứu cũng chỉ ra rằng việc kết hợp giữa các công nghệ học sâu hiện đại và các framework chuyên biệt cho ảnh y tế như PyTorch, MONAI hay PyTorch Lightning giúp tối ưu hóa quy trình phát triển mô hình, tăng khả năng tái lặp và mở rộng trong các nghiên cứu sau này.

Nhìn chung, đề tài đã đạt được các mục tiêu nghiên cứu đề ra, bao gồm:

Xây dựng được quy trình xử lý và phân tích ảnh X-quang xương phục vụ cho bài toán phát hiện ung thư.

Phát triển và huấn luyện mô hình học sâu có khả năng phân đoạn vùng tổn thương trên ảnh y tế.

Đánh giá hiệu quả mô hình bằng các chỉ số chuyên môn và phân tích kết quả thực nghiệm.

Đề xuất một hướng tiếp cận khả thi cho việc ứng dụng trí tuệ nhân tạo trong hỗ trợ chẩn đoán ung thư xương.

Mặc dù đạt được những kết quả tích cực, nghiên cứu vẫn còn một số hạn chế nhất định như quy mô dữ liệu còn hạn chế, dữ liệu chưa phản ánh đầy đủ đặc điểm bệnh lý của bệnh nhân tại Việt Nam và hệ thống chưa được thử nghiệm trực tiếp trong môi trường lâm sàng. Tuy nhiên, các kết quả đạt được cho thấy tiềm năng lớn của phương pháp trong việc phát triển các hệ thống hỗ trợ chẩn đoán tự động trong tương lai.

5. Khuyến nghị và hướng phát triển

Từ các kết quả đạt được trong nghiên cứu, một số định hướng phát triển và khuyến nghị được đề xuất nhằm nâng cao hiệu quả và khả năng ứng dụng thực tiễn của hệ thống trong tương lai.

Thứ nhất, cần mở rộng và đa dạng hóa nguồn dữ liệu huấn luyện. Việc thu thập thêm dữ liệu từ các bệnh viện trong nước sẽ giúp mô hình học được các đặc điểm hình ảnh phù hợp hơn với dân số Việt Nam, từ đó nâng cao độ chính xác và khả năng ứng dụng trong môi trường lâm sàng thực tế.

Thứ hai, nghiên cứu có thể mở rộng sang các kiến trúc mạng học sâu tiên tiến hơn như Attention U-Net, UNet++, hoặc các mô hình kết hợp Transformer nhằm cải thiện khả năng nhận diện các vùng tổn thương nhỏ hoặc có ranh giới phức tạp.

Thứ ba, cần phát triển các phương pháp giải thích mô hình (Explainable AI – XAI) nhằm tăng tính minh bạch của hệ thống. Việc trực quan hóa các vùng mà

mô hình tập trung khi đưa ra quyết định sẽ giúp bác sĩ dễ dàng hiểu và tin tưởng hơn vào kết quả dự đoán của hệ thống AI.

Thứ tư, hệ thống nên được tích hợp vào các nền tảng phần mềm hỗ trợ chẩn đoán y khoa để tạo thành một công cụ hỗ trợ thực tế cho bác sĩ. Việc xây dựng giao diện trực quan, dễ sử dụng và kết nối với hệ thống lưu trữ ảnh y khoa (PACS) sẽ giúp tăng tính ứng dụng của nghiên cứu.

Cuối cùng, trong các nghiên cứu tiếp theo, có thể mở rộng bài toán từ phân đoạn sang các nhiệm vụ phức tạp hơn như phân loại loại ung thư xương, dự đoán mức độ ác tính hoặc dự đoán tiên lượng điều trị thông qua việc kết hợp dữ liệu hình ảnh với các dữ liệu lâm sàng khác.

TÀI LIỆU THAM KHẢO

[1] Y. H. Shunhan Yao, Xiaoyu Wang, Yiwen Zhang, Ian Costa Paixao, et al., "A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors," *Scientific Data,* vol. 12, no. 1, 2025, doi: 10.1038/s41597-024-04311-y.

[2] B. L. Danyang Xu, Weixiang Liu, Dan Wei, Xiaowu Long, et al., "Deep learning-based detection of primary bone tumors around the knee joint on radiographs: a multicenter study," *Quantitative Imaging in Medicine and Surgery,* vol. 14, no. 8, 2024, doi: 10.21037/qims-23-1743.

[3] D. Y. Ilkay Yildiz Potter, Sarah Mahar, Jim Wu, Ara Nazarian, et al., "Automated Bone Tumor Segmentation and Classification as Benign or Malignant Using Computed Tomographic Imaging," *Journal of Digital Imaging,* vol. 36, no. 3, pp. 869-878, 2023, doi: 10.1007/s10278-022-00771-z.

[4] V. D. Rathla Roop Singh, "Deep Dive into Bone Tumor Segmentation and Classification: Methodological Review and Challenges with Deep Learning Approaches," *ITM Web of Conferences,* vol. 74, 2025, doi: 10.1051/itmconf/20257401006.

[5] I. P. Yu He, Bingting Bao, Kasey Halsey, Marcello Chang, et al., "Deep learning-based classification of primary bone tumors on radiographs: A preliminary study," *EBioMedicine,* vol. 62, 2020, Art no. 103121.

[6] S.-T. J. Nhu-Tai Do, Hyung-Jeong Yang, Soo-Hyung Kim, "Multi-Level Seg-Unet Model with Global and Patch-Based X-ray Images for Knee Bone Tumor Detection," *Diagnostics,* vol. 11, no. 4, 2021, doi: 10.3390/diagnostics11040691.

[7] B. Tuan. "Tiến triển trong chẩn đoán X quang u xương." Bs X-Quang Tuan's blog. https://bsxqtuan.wordpress.com/2013/05/02/tien-trien-trong-chan-doan-x-quang-u-xuon/ (accessed.

[8] T. P. C. T. Hồ Kim Thương, "Khảo sát đặc điểm lâm sàng và cận lâm sàng của u xương các xoang cạnh mũi ở bệnh viện Tai Mũi Họng TP Hồ Chí

Minh từ tháng 06/2016 đến tháng 06/2017," *Tạp chí Y học Thành phố Hồ Chí Minh,* vol. 22, no. 1, p. 117, 2018.

[9] W. C. Röntgen, "On a New Kind of Rays," *Nature,* vol. 53, no. 1369, pp. 274-276, 1895, doi: 10.1038/053274b0.

[10] J. Ewing, "Classic article: Diffuse endothelioma of bone," vol. 22, no. 2, pp. 95-98, 1972, doi: 10.3322/canjclin.22.2.95.

[11] D. C. Dahlin, *Bone Tumors: General Aspects and Data on 2,276 Cases*. Springfield, Illinois (Mỹ): Charles C Thomas, 1957.

[12] e. a. Lindsey M. Allison, "Update on Survival in Osteosarcoma," *Orthopedic Clinics of North America,* vol. 43, no. 1, pp. 81-93, 2012, doi: 10.1016/j.ocl.2015.08.022.

[13] M. J. K. Mark D. Murphey, "MR imaging of tumor and tumorlike lesions of bone and soft tissue," vol. 155, no. 4, 1990 doi: 10.2214/ajr.155.4.2119115.

[14] S. S. S. William F. Enneking, M. A. Goodman, "A system for the surgical staging of musculoskeletal sarcoma," *Clinical Orthopaedics and Related Research,* vol. 153, pp. 106-120, 1980, doi: 10.1097/01.blo.0000093891.12372.0f.

[15] G. Rosen, Marcove, R. C., Caparros, B., Nirenberg, A., Kosloff, C., & Huvos, A. G., "Primary osteogenic sarcoma: The rationale for preoperative chemotherapy and delayed surgery.," *Cancer,* vol. 43, no. 6, pp. 2163–2177, 1979, doi: 10.1002/1097-0142(197906)43:6<2163::aid-cncr2820430602>3.0.co;2-s.

[16] E. R.-V. Philippe Lambin, Ralph Leijenaar, Sara Carvalho, ... & Hugo J. W. L. Aerts, "Radiomics: Extracting more information from medical images using advanced feature analysis," *European Journal of Cancer,* vol. 48, no. 4, pp. 441–446, 2012, doi: 10.1016/j.ejca.2011.11.036.

[17] O. D. Rashindra Mishra, Patrick Leavey, Dinesh Rakheja, Animesh Sengupta, "Convolutional neural network for histopathological analysis of osteosarcoma," *Computerized Medical Imaging and Graphics (CMIG),* vol. 69, pp. 17–25, 2017, doi: 10.1089/cmb.2017.0153.

[18] P. F. Olaf Ronneberger, Thomas Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," *Medical Image Computing and Computer-Assisted Intervention (MICCAI),* pp. 234-241, 2015, doi: 10.1007/978-3-319-24574-4_28.

[19] P. I. Jun-Yan Zhu, Alexei Efros, Taesung Park, "Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks," 2017, doi: 10.1109/ICCV.2017.244.

[20] J. W. Yafei Jiang, Mengxiong Sun, Dongqing Zuo, Hongsheng Wang, et al., "Multi-omics analysis identifies osteosarcoma subtypes with distinct prognosis indicating stratified treatment," *Nature Communications,* vol. 13, 2022, doi: 10.1038/s41467-022-34689-5.

[21] P. A. Sudhir Kumar Garg, Jagandeep Virk, R P S Punia, Kislay Dimri, Rohit Jindal, "Limb Salvage Using Liquid Nitrogen–Treated Osteosarcoma at the Distal Tibia: A Case Report," *Vietnam Medical Journal,* pp. 200–207, 2020, doi: 10.1007/s43465-019-00001-9.

[22] Y. P. Sihan Chen, Yingxuan Liu, Pengyu Wang, Tao Liu, "Enhancing YOLOv11 with Large Kernel Attention and Multi-Scale Fusion for Accurate Small and Multi-Lesion Bone Tumor Detection in Radiographs," *Diagnostics,* vol. 15, no. 16, 2025, doi: https://doi.org/10.3390/diagnostics15161988.

THUYẾT MINH

ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

Thành phố Hồ Chí Minh, ngày 08 tháng 10 năm 2025

THUYẾT MINH ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CẤP TRƯỜNG CỦA SINH VIÊN

1. Tên đề tài: XÂY DỰNG HỆ THỐNG NHẬN DIỆN UNG THƯ XƯƠNG THÔNG QUA ẢNH CHỤP X-QUANG
Mã số đề tài: SVC2025-184
2. Lĩnh vực nghiên cứu:

Khoa học Tự nhiên	☒	Khoa học Kỹ thuật và Công nghệ	☐
Khoa học Y, dược	☐	Khoa học Nông nghiệp	☐
Khoa học Xã hội	☐	Khoa học Nhân văn	☐

Loại đề tài: ☐ A ☐ B1 ☐ B2 ☒ C

3. Thời gian thực hiện: 7 tháng từ tháng 10/2025 - tháng 4/2026

4. Chủ nhiệm đề tài

Họ và tên: Trần Đồng Gia Hân
Chương trình đào tạo: Công Nghệ Thông Tin.
MSSV: 3121411066 Lớp: DCT21C3 Khoa: Công Nghệ Thông Tin
Điện thoại di động: 0769834162 E-mail: trandonggiahan2003@gmail.com

5. Các thành viên tham gia thực hiện đề tài *(cần ghi rõ nhiệm vụ của từng người, kể cả chủ nhiệm đề tài)*

STT	Họ và tên	Đơn vị (MSSV, lớp, CTĐT)	Nội dung nghiên cứu cụ thể được giao	Chữ ký
1	Trần Đồng Gia Hân	3121411066, DCT121C3, Công nghệ thông tin	Nhóm trưởng: Chịu trách nhiệm chung. Đọc các nghiên cứu, sách báo, tạp chí khoa học, tài liệu liên quan đến đề tài. Tìm hiểu và nghiên cứu các thực nghiệm liên quan. Tổng hợp các kết quả thực	

			nghiệm. Viết báo cáo tổng hợp	
2	Lê Thị Thanh Ngân	3121411143, DCT121C3, Công nghệ thông tin	Đọc các nghiên cứu, sách báo, tạp chí khoa học, tài liệu liên quan đến đề tài. Tìm hiểu và nghiên cứu các thực nghiệm liên quan. Tổng hợp các kết quả thực nghiệm. Viết báo cáo tổng hợp.	
3	Trần Minh Chiến	3121411028, DCT121C3, Công nghệ thông tin	Đọc các nghiên cứu, sách báo, tạp chí khoa học, tài liệu liên quan đến đề tài. Tìm hiểu và nghiên cứu các thực nghiệm liên quan. Tổng hợp các kết quả thực nghiệm. Viết báo cáo tổng hợp.	
4	Vũ Đức Tình	3121410510, DCT1212, Công nghệ thông tin	Đọc các nghiên cứu, sách báo, tạp chí khoa học, tài liệu liên quan đến đề tài. Tìm hiểu và nghiên cứu các thực nghiệm liên quan. Tổng hợp các kết quả thực nghiệm. Viết báo cáo tổng hợp.	

6. Mô tả năng lực nghiên cứu chủ nhiệm và các thành viên

Các thành viên thực hiện đề tài đều là sinh viên năm cuối ngành Công nghệ Thông tin, đã tích lũy nền tảng kiến thức vững chắc về lập trình Python, trí tuệ nhân tạo và xử lý ảnh y tế thông qua các học phần như Machine Learning, Deep Learning và Đồ án chuyên ngành. Nhóm có kinh nghiệm thực hành với các thư viện học sâu phổ biến như TensorFlow, Keras, PyTorch, cũng như các thư viện chuyên dụng trong lĩnh vực y tế như MONAI.

Về khả năng xử lý dữ liệu, các thành viên thành thạo thao tác với nhiều định dạng ảnh y tế như JPEG, JSON, NIfTI, đảm bảo khả năng tiền xử lý và chuẩn hóa dữ liệu phục vụ cho việc huấn luyện mô hình. Bên cạnh đó, nhóm cũng đã làm quen và áp dụng nền tảng Weights & Biases (WandB) để theo dõi và trực quan hóa quá trình huấn luyện, phân tích các chỉ số đánh giá quan trọng như IoU, Dice Coefficient, Precision và Recall.

Với năng lực chuyên môn phù hợp và khả năng phối hợp nhóm hiệu quả, nhóm nghiên cứu có đủ điều kiện để thực hiện đề tài đúng tiến độ và đạt được các mục tiêu khoa học đề ra.

7. Cán bộ hướng dẫn sinh viên thực hiện đề tài

Họ và tên	số ĐTDĐ	Khoa	Chữ ký
Đỗ Như Tài	0909969618	Công nghệ thông tin	

8. Tình hình nghiên cứu liên quan đến đề tài *(Tổng quan tình hình nghiên cứu trong và ngoài nước; phân tích, đánh giá những kết quả đạt được, xác định những tồn tại hạn chế của công bố liên quan đến lĩnh vực của đề tài; thống kê tài liệu tham khảo đã sử dụng):*

Hiện nay, tại Việt Nam chưa có công trình công bố chính thức ứng dụng học sâu cho bài toán phân đoạn tự động khối u xương trên ảnh X-quang. Tuy nhiên, một số tài liệu y học trong nước đã cung cấp nền tảng chuyên môn hữu ích. Bác sĩ X-quang Tuấn [1] đề cập đến vai trò của chẩn đoán hình ảnh trong nhận diện u xương và nhu cầu cấp thiết về các công cụ hỗ trợ bác sĩ lâm sàng. Nghiên cứu của Hồ Kim Thương và Trần Phan Chung Thủy [2] khảo sát đặc điểm lâm sàng của u xương xoang cạnh mũi tại Bệnh viện Tai Mũi Họng TP.HCM, nhấn mạnh vai trò của CT-scan nhưng chưa đề cập đến trí tuệ nhân tạo. Bên cạnh đó, tài liệu từ MSD Manual [3] cung cấp kiến thức tổng quan về chẩn đoán u xương, qua đó gợi mở tiềm năng ứng dụng AI vào lĩnh vực này.

Ở bình diện quốc tế, nhiều nghiên cứu tiên phong đã đặt nền móng cho ứng dụng học sâu trong chẩn đoán hình ảnh xương. He et al. [4] sử dụng mô hình ResNet để phân loại khối u xương lành tính và ác tính trên ảnh X-quang, tuy nhiên vẫn giới hạn ở mức độ phân loại toàn ảnh. Xu et al. [5] triển khai mô hình học sâu đa trung tâm để phát hiện u xương quanh khớp gối từ ảnh X-quang, với khả năng tổng quát cao và kết quả thực nghiệm đáng tin cậy trên nhiều nguồn dữ liệu. Đặc biệt, Do et al. [6] đề xuất mô hình Multi-Level Seg-Unet kết hợp thông tin toàn ảnh và từng vùng cục bộ nhằm phân đoạn u xương đầu gối hiệu quả. Mô hình đạt độ chính xác phân loại 99,05% và Mean IoU lên đến 84,84%, chứng minh hiệu suất cao trong bài toán phân đoạn vùng tổn thương.

Tổng thể, các nghiên cứu trên khẳng định tiềm năng ứng dụng mạnh mẽ của học sâu trong phân tích ảnh X-quang xương. Tuy nhiên, phần lớn vẫn mang tính học thuật, chưa phát triển thành hệ thống ứng dụng triển khai được tại tuyến cơ sở. Vì vậy, đề tài này hướng đến việc kế thừa các thành tựu quốc tế, đồng thời mở rộng và điều chỉnh để phù hợp với điều kiện, dữ liệu và nhu cầu triển khai thực tế tại Việt Nam.

Tài liệu tham khảo

[1] B.S. Tuấn, "Tiến triển trong chẩn đoán X-quang u xương," Blog Bác sĩ X-quang, 2013. [Online]. Available: https://bsxqtuan.wordpress.com/2013/05/02/tien-trien-trong-chan-doan-x-quang-u-xuon/

[2] H. K. Thương and T. P. C. Thủy, "Khảo sát đặc điểm lâm sàng và cận lâm sàng của u xương các xoang cạnh mũi tại Bệnh viện Tai Mũi Họng TP. Hồ Chí Minh," Tạp chí Y học TP. Hồ Chí Minh, phụ bản Tập 22, Số 1, tr. 117–122, 2018.

[3] MSD Manual Professional Version, "Tổng quan u xương và u khớp," MSD Manual Tiếng Việt, 2023. [Online]. Available: https://www.msdmanuals.com/vi/professional/rối-loạn-mô-cơ-xương-và-mô-liên-kết/u-xương-khớp/tổng-quan-u-xương-và-u-khớp

[4] H. He, H. Zhang, Z. Jiang, et al., "Deep learning-based classification of primary bone tumors on radiographs: A preliminary study," EBioMedicine, vol. 62, 2020.

[5] Y. Xu, L. Zhang, J. Zhao, et al., "Deep learning-based detection of primary bone tumors around the knee joint on radiographs: a multicenter study," Quantitative Imaging in Medicine and Surgery, vol. 14, no. 1, pp. 77–87, 2024.

[6] N.-T. Do, S.-T. Jung, H.-J. Yang, and S.-H. Kim, "Multi-Level Seg-Unet Model with Global and Patch-Based X-ray Images for Knee Bone Tumor Detection," Diagnostics, vol. 11, no. 4, 691, 2021. https://doi.org/10.3390/diagnostics11040691

9. Tính cấp thiết của đề tài *(từ đánh giá tổng quan tình hình nghiên cứu, nêu được hướng giải quyết vấn đề còn tồn tại liên quan đến đề tài; làm rõ mức độ cần thiết của việc thực hiện đề tài, đóng góp mới của đề tài đối với ngành, đối với tổ chức chủ trì, đối với xã hội):*

Ung thư xương là bệnh lý ác tính nguy hiểm, có khả năng tiến triển nhanh và tỷ lệ tử vong cao nếu không được phát hiện sớm. Tuy nhiên, tại Việt Nam, việc chẩn đoán vẫn chủ yếu dựa vào kinh nghiệm bác sĩ và thiết bị truyền thống, trong khi các nghiên cứu ứng dụng học sâu để phân đoạn hình ảnh X-quang còn rất hạn chế. Tình trạng này dẫn đến nguy cơ phát hiện bệnh muộn, giảm hiệu quả điều trị và tăng chi phí y tế.

Trong bối cảnh đó, việc phát triển hệ thống hỗ trợ chẩn đoán bằng trí tuệ nhân tạo là nhu cầu cấp thiết. Đề tài hướng đến xây dựng mô hình học sâu có khả năng phân đoạn tự

động vùng nghi ngờ ung thư trên ảnh X-quang, giúp giảm tải cho bác sĩ, nâng cao độ chính xác và rút ngắn thời gian chẩn đoán.

Không chỉ đáp ứng yêu cầu thực tiễn trong lĩnh vực y tế, đề tài còn góp phần thúc đẩy chuyển đổi số ngành y tại Việt Nam, mở ra khả năng ứng dụng rộng rãi tại bệnh viện, trung tâm chẩn đoán hình ảnh, đặc biệt ở những nơi thiếu bác sĩ chuyên khoa. Đây là sự kết hợp thiết thực giữa công nghệ thông tin và y học nhằm phục vụ chăm sóc sức khỏe cộng đồng.

10. Mục tiêu đề tài *(Nêu mục tiêu chung, các mục tiêu cụ thể phù hợp với tên đề tài, tính cấp thiết của đề tài, kết quả cuối cùng mà đề tài hướng đến):*

Mục tiêu chung của đề tài là phát triển một hệ thống ứng dụng học sâu có khả năng phân đoạn tự động vùng tổn thương ung thư xương trên ảnh X-quang, nhằm hỗ trợ bác sĩ chẩn đoán chính xác, nhanh chóng và giảm phụ thuộc vào yếu tố chủ quan.

Để hiện thực hóa mục tiêu này, đề tài đề ra các mục tiêu cụ thể như sau:

- Tiền xử lý và chuẩn hóa ảnh từ bộ dữ liệu chuẩn quốc tế BTXRD.
- Xây dựng mô hình học sâu tối ưu cho bài toán phân đoạn khối u xương.
- Huấn luyện và đánh giá mô hình bằng các chỉ số chuyên ngành như Dice Coefficient, IoU, Precision và Recall.
- Xây dựng ứng dụng mẫu với giao diện đơn giản, cho phép người dùng tải ảnh và hiển thị kết quả phân đoạn trực quan.

Kết quả cuối cùng hướng đến là một mô hình phân đoạn chính xác cao được tích hợp trong ứng dụng thử nghiệm, sẵn sàng cho đánh giá và triển khai thực tế tại cơ sở y tế.

11. Đối tượng và phạm vi nghiên cứu *(xác định rõ đối tượng nghiên cứu, phạm vi nghiên phù hợp với tên đề tài, mục tiêu của đề tài):*

Đối tượng nghiên cứu: Đối tượng nghiên cứu của đề tài là các ảnh X-quang 2D (hoặc ảnh CT nếu có), được thu thập từ bệnh nhân có nghi ngờ hoặc đã được chẩn đoán mắc ung thư xương. Những hình ảnh này chứa thông tin quan trọng về cấu trúc xương và vùng tổn thương, là cơ sở dữ liệu đầu vào cho việc huấn luyện và đánh giá mô hình học sâu.

Phạm vi nghiên cứu: Đề tài tập trung vào việc xây dựng mô hình học sâu cho nhiệm vụ phân đoạn chính xác vùng tổn thương xương trên ảnh X-quang. Ngoài việc phát triển mô hình, nghiên cứu còn triển khai thử nghiệm và đánh giá trên bộ dữ liệu chuẩn BTXRD, từ đó xây dựng nguyên mẫu ứng dụng có khả năng áp dụng thực tiễn trong môi trường y tế Việt Nam.

Đề tài cũng xem xét các thách thức đặc thù trong xử lý ảnh xương, như độ phức tạp cấu trúc mô xương, sự tương đồng giữa mô lành và vùng bệnh, nhằm đảm bảo mô hình có độ chính xác cao và khả năng tổng quát tốt khi triển khai thực tế.

12. Phương pháp nghiên cứu *(trình bày cụ thể cách tiếp cận, các nguồn dữ liệu và cách thu thập dữ liệu; Mô tả chi tiết phương pháp, quy trình chọn mẫu và cách thức thu thập và phân tích số liệu; lý giải việc lựa chọn của tác giả):*

Đề tài áp dụng phương pháp nghiên cứu kết hợp giữa lý thuyết và thực nghiệm, tập trung vào phát triển mô hình học sâu cho bài toán phân đoạn ảnh X-quang xương.

Cách tiếp cận được thực hiện theo các bước chính sau:

- Nghiên cứu cơ sở lý thuyết: Tìm hiểu về học sâu, mạng nơ-ron tích chập (CNN), các kiến trúc phân đoạn phổ biến (như U-Net, SegNet), và các kỹ thuật tối ưu hóa trong huấn luyện mô hình y sinh. Đồng thời phân tích đặc điểm hình ảnh X-quang xương và các thách thức trong nhận diện tổn thương.
- Thu thập và tiền xử lý dữ liệu: Sử dụng bộ dữ liệu chuẩn quốc tế BTXRD với các ảnh X-quang đã được chuyên gia chú thích. Ảnh sẽ được chuẩn hóa kích thước, loại bỏ vùng nhiễu và cân chỉnh độ tương phản để đảm bảo đầu vào nhất quán. Các kỹ thuật tiền xử lý như lọc nhiễu, chuyển đổi kênh màu và trích xuất ROI sẽ được áp dụng.
- Xây dựng và huấn luyện mô hình: Mô hình học sâu được thiết kế và triển khai với các hàm mất mát chuyên dụng cho phân đoạn như Dice Loss hoặc Focal Loss. Kỹ thuật tăng cường dữ liệu (Data Augmentation) được sử dụng để cải thiện khả năng tổng quát và giảm overfitting.
- Đánh giá và tối ưu hóa: Mô hình được đánh giá bằng các chỉ số phổ biến như Dice Coefficient, IoU, Precision và Recall. Kết quả đánh giá sẽ được sử dụng để tinh chỉnh mô hình và lựa chọn kiến trúc tối ưu.
- Thử nghiệm và cải tiến: Mô hình được thử nghiệm trên các tập dữ liệu khác nhau để kiểm tra tính ổn định và khả năng ứng dụng trong thực tế. Các đề xuất cải tiến sẽ được đưa ra nhằm tăng hiệu năng và độ tin cậy khi triển khai trong môi trường y tế.

Việc lựa chọn phương pháp này giúp đảm bảo đề tài vừa có nền tảng lý thuyết vững chắc, vừa bám sát yêu cầu thực tiễn trong chẩn đoán hình ảnh y học tại Việt Nam.

13. Nội dung nghiên cứu và tiến độ thực hiện

13.1. Nội dung nghiên cứu *(nêu rõ từng nội dung gắn với các mục tiêu cụ thể)*

261

Tổng kinh phí: 5.000.000 đ
Trong đó: Ngân sách Nhà nước: 5.000.000đ Các nguồn kinh phí khác: 0đ
Dự trù kinh phí theo các mục chi *(dự trù kinh phí cho mỗi mục nhỏ và được trình bày phù hợp với mục tiêu, nội dung và phương pháp nghiên cứu):*
Đơn vị tính: đồng

Số tiền bằng chữ*: năm triệu đồng.*

TT	Nội dung chi	Kinh phí
1	**Chi tiền công thực hiện đề tài:**	**4.800.000**
	- Thù lao chủ nhiệm đề tài, quản lý chung	1.200.000
	- Điều tra, khảo sát ban đầu, xây dựng đề cương, thuyết minh...	2.400.000
	- Khảo sát, nghiên cứu thực địa, tổng hợp tài liệu, viết báo cáo…	1.200.000
2	**Chi thuê khoán chuyên môn:**	**0**
	- Thuê nhập liệu, xử lý số liệu	0
	- Phân tích mẫu thí nghiệm, đo đạc, xử lý kết quả đo…	0
	- Các công việc thuê khoán khác	0
3	**Mua nguyên vật liệu**: - Hóa chất - Dụng cụ - Tài liệu tham khảo - Các nguyên vật liệu khác phục vụ nghiên cứu	**0**
4	**Chi phí khác:** - In ấn, pho to	**200.000**
	Tổng số	**5.000.000**

Ngày 09 tháng 10 năm 2025

Xác nhận của Khoa	**Cán bộ hướng dẫn**	**Chủ nhiệm đề tài**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*	*(Ký và ghi rõ họ tên)*
PGS.TS. Phạm Thế Bảo	Hồ Thị Tú	Trần Đồng Gia Hân

DUYỆT CỦA TRƯỜNG ĐẠI HỌC SÀI GÒN
KT. HIỆU TRƯỞNG
PHÓ HIỆU TRƯỞNG

PGS.TS. Lê Minh Triết